



การวิเคราะห์และพยากรณ์อัตราการลาออกของพนักงานโดยใช้เทคนิคเหมืองข้อมูล
Analysis and Forecasting of Employee Turnover Rate using Data Mining
Techniques

โดย

นาย พิสิษฐ์พล จันทระกิตติกุล
รหัสนักศึกษา 6623765507

โครงงานนี้เป็นส่วนหนึ่งของรายวิชา

ดท. 224 โครงการด้านการวิเคราะห์ข้อมูลสำหรับธุรกิจ

หลักสูตรวิทยาศาสตรบัณฑิต นวัตกรรมและการแปรรูปทางดิจิทัล

วิทยาลัยนวัตกรรม มหาวิทยาลัยธรรมศาสตร์ ภาคการศึกษาที่ 2 ปีการศึกษา 2567

บทคัดย่อ

การลาออกของพนักงานเป็นปัญหาสำคัญที่ส่งผลกระทบต่อประสิทธิภาพขององค์กร ทั้งในด้านต้นทุน ทรัพยากร และความต่อเนื่องในการดำเนินงาน งานวิจัยนี้มีวัตถุประสงค์เพื่อศึกษาปัจจัยที่ส่งผลต่อการลาออกของพนักงาน โดยใช้แนวทางการวิเคราะห์ข้อมูลเชิงลึกเพื่อให้สามารถเข้าใจพฤติกรรมและรูปแบบที่เกี่ยวข้องกับการตัดสินใจลาออกได้อย่างชัดเจน

โครงการนี้นำเทคนิคเหมืองข้อมูลหลากหลายรูปแบบมาประยุกต์ใช้ ได้แก่ การจำแนกประเภท (Classification) เพื่อคาดการณ์ว่าพนักงานคนใดมีแนวโน้มลาออก, การจัดกลุ่ม (Clustering) เพื่อค้นหารูปแบบพนักงานที่มีคุณลักษณะคล้ายกัน, และการค้นหากฎความสัมพันธ์ (Association Rule Mining) เพื่อระบุปัจจัยที่สัมพันธ์กับพฤติกรรมการลาออกจากหลายเงื่อนไขร่วมกัน โดยใช้ชุดข้อมูลพนักงานจำนวน 10,000 รายการซึ่งประกอบด้วยตัวแปรทั้งเชิงตัวเลขและเชิงหมวดหมู่

ผลการวิเคราะห์สามารถนำไปใช้เพื่อวางแผนกลยุทธ์ด้านทรัพยากรมนุษย์ในเชิงรุก เช่น การออกแบบนโยบายรักษาพนักงานที่มีแนวโน้มลาออก การพัฒนาแผนสืบทอดตำแหน่ง และการวางโครงสร้างค่าตอบแทนให้สอดคล้องกับปัจจัยเสี่ยง ตลอดจนสนับสนุนการตัดสินใจในระดับผู้บริหารเพื่อเพิ่มความมั่นคงและลดอัตราการสูญเสียบุคลากรในระยะยาว

คำสำคัญ: การลาออกของพนักงาน, เหมืองข้อมูล, การวิเคราะห์เชิงพยากรณ์

Abstract

Employee attrition is a critical issue that directly affects an organization's performance in terms of cost, resources, and operational continuity. This study aims to identify the factors influencing employee turnover through in-depth data analysis, enabling a clearer understanding of behaviors and patterns associated with resignation decisions.

This project applies various data mining techniques, including Classification to predict which employees are likely to resign, Clustering to uncover groups of employees with similar characteristics, and Association Rule Mining to identify complex relationships between multiple risk factors. The analysis is based on a dataset of 10,000 employee records, comprising both numerical and categorical variables.

The findings can be used to develop proactive human resource strategies—such as retention policies, succession planning, and compensation structuring aligned with risk factors. These insights also support executive decision-making to strengthen workforce stability and reduce long-term employee loss.

Keywords: Employee Attrition, Data Mining, Predictive Analytics

กิตติกรรมประกาศ

โครงงานฉบับนี้เป็นส่วนหนึ่งของการบูรณาการความรู้ของนักศึกษาชั้นปีที่ 2 สาขาวิศวกรรมและการแปรรูปทางดิจิทัล วิทยาลัยนวัตกรรม มหาวิทยาลัยธรรมศาสตร์ ภายใต้บทเรียนวิชาโครงงานด้านการวิเคราะห์ข้อมูลสำหรับธุรกิจ โดยครอบคลุมกระบวนการวิเคราะห์ข้อมูลตั้งแต่การทำความเข้าใจปัญหาและข้อมูล (Problem and Data Understanding), การสำรวจและตรวจสอบคุณภาพข้อมูล (Data Exploration & Data Quality), การเตรียมข้อมูล (Data Preparation), การสร้างแบบจำลองข้อมูล (Data Modeling) รวมถึงการสื่อความผ่านภาพข้อมูล (Data Visualization) เพื่อให้สามารถวิเคราะห์เชิงลึกและนำไปประยุกต์ใช้ในบริบทจริงได้อย่างมีประสิทธิภาพ

ผู้จัดทำขอกราบขอบพระคุณผู้ช่วยศาสตราจารย์ ดร.อัจฉรา ภู่อ่าง อาจารย์ที่ปรึกษาโครงงานที่ให้คำแนะนำอย่างใกล้ชิดในทุกขั้นตอน ตั้งแต่การเลือกหัวข้อ แนวทางการวิเคราะห์ ไปจนถึงการเลือกใช้เทคนิคที่เหมาะสม ตลอดจนการชี้แหล่งข้อมูลอันเป็นประโยชน์อย่างยิ่งต่อการดำเนินโครงงานฉบับนี้

ขอขอบคุณอาจารย์ผู้สอนทุกท่านที่มอบองค์ความรู้และแนวทางการคิดวิเคราะห์ตลอดระยะเวลาการศึกษา หากโครงงานฉบับนี้มีข้อผิดพลาดหรือบกพร่องในส่วนใด ผู้จัดทำขอน้อมรับไว้เพื่อเป็นแนวทางในการปรับปรุงและพัฒนาต่อไปในอนาคต

พิสิษฐ์พล จันทรกิตติกุล

สารบัญ

เรื่อง	หน้า
บทคัดย่อ	i
Abstract	ii
กิตติกรรมประกาศ	iii
สารบัญ	iv
สารบัญภาพ	vi
สารบัญตาราง	viii
บทที่ 1 การทำความเข้าใจปัญหา (Problem Understanding)	1
1.1 ความเป็นมาและความสำคัญของปัญหา (Introduction and Problem Statement)	1
1.2 วัตถุประสงค์ (Objectives)	2
1.3 ประโยชน์ (Benefaction)	2
1.4 กรอบโครงการ (Project Framework)	2
1.5 แผนการดำเนินการ (Action Plan)	2
1.6 การทบทวนวรรณกรรม (Literature Reviews)	3
บทที่ 2 การทำความเข้าใจข้อมูล (Data Understanding)	8
2.1 การอธิบายข้อมูล (Data Description)	8
2.2 การสำรวจข้อมูล (Data Exploration)	9
2.3 คุณภาพข้อมูล (Verify Data quality)	17
บทที่ 3 การจัดเตรียมข้อมูล (Data Preparation)	24
3.1 การคัดเลือกข้อมูล (Feature Selection)	24
3.2 การสร้างชุดข้อมูล (Data Construction)	27
บทที่ 4 การสร้างแบบจำลองข้อมูล (Data Modeling)	30
4.1 การเลือกใช้เทคนิคแบบจำลอง (Select Modelling Technique)	30
4.2 ตัวแบบเหมืองข้อมูล (Data Mining Model)	31

4.3 การทดสอบและประเมินความแม่นยำของตัวแบบเหมืองข้อมูล (Data Mining Model Testing and Assessment)	38
บทที่ 5 สรุปผล อภิปรายผลและข้อเสนอแนะ (Conclusion, Discussion and Suggestion)	42
5.1 การสรุปผล (Conclusion)	42
5.2 การอภิปรายผล (Discussion)	47
5.3 ข้อเสนอแนะ (Suggestion)	54
เอกสารอ้างอิง	55

สารบัญภาพ

ภาพ	หน้า
รูปภาพที่ 1 กราฟ Logistic Regression	4
รูปภาพที่ 2 แผนผังต้นไม้ของ Random Forest	5
รูปภาพที่ 3 การทำงานของ Neural Network	5
รูปภาพที่ 4 การทำงานของ K-Means Clustering	6
รูปภาพที่ 5 ตัวอย่าง Association Rule	6
รูปภาพที่ 6 ตัวอย่าง Imbalanced Data	7
รูปภาพที่ 7 ตาราง Evaluation Metrics	7
รูปภาพที่ 8 - 11แสดงรายละเอียดของข้อมูลเบื้องต้น	8
รูปภาพที่ 12 - 13 แสดงประเภทของข้อมูล	10
รูปภาพที่ 14 - 16 ค่าต่าง ๆ ของแต่ละ Numerical Attributes	10
รูปภาพที่ 17 ค่าต่าง ๆ ของแต่ละ Categorical Attributes	10
รูปภาพที่ 18 - 20 แสดงการแจกแจงของข้อมูลประเภท Categorical ในแต่ละ Attributes	13
รูปภาพที่ 21 - 30 แสดงการแจกแจงของข้อมูลประเภท Numerical ในแต่ละ Attributes	15
รูปภาพที่ 31 แสดงโค้ดในการตรวจสอบ Accuracy	17
รูปภาพที่ 32 - 41 กราฟแสดง outlier ตัวแปรเชิงตัวเลขที่ไม่ใช่ข้อมูลแบบ Binary	20
รูปภาพที่ 42 แสดงโค้ดในการตรวจสอบ Completeness	21
รูปภาพที่ 43 ผลลัพธ์การตรวจสอบ Completeness	21
รูปภาพที่ 44 แสดงโค้ดในการตรวจสอบ Consistency	22
รูปภาพที่ 45 ผลลัพธ์การตรวจสอบ Consistency	22
รูปภาพที่ 46 แสดงโค้ดในการตรวจสอบ Timeliness	22
รูปภาพที่ 47 แสดงโค้ดในการตรวจสอบ Uniqueness	23
รูปภาพที่ 48 ผลลัพธ์การตรวจสอบ Uniqueness	23
รูปภาพที่ 49 แสดงโค้ด Encoding (Label + One-hot Encoding)	24
รูปภาพที่ 50 แสดงตัวอย่างผลลัพธ์หลังจาก Encoding (Label + One-hot Encoding)	25
รูปภาพที่ 51 แสดงโค้ด Feature Selection Using Correlation + Forest Features Importance	25
รูปภาพที่ 52 กราฟแสดงตัวอย่างผลลัพธ์ Correlation + Forest Features Importance	26
รูปภาพที่ 53 แสดงโค้ด Oversampling (SMOTE)	27
รูปภาพที่ 54 - 55แสดงผลลัพธ์หลังจากทำ Oversampling (SMOTE)	28

รูปภาพที่ 56 แสดงโค้ด Standardization	28
รูปภาพที่ 57 - 58 กราฟแสดงการเปรียบเทียบค่าเฉลี่ย (mean) และส่วนเบี่ยงเบนมาตรฐาน (standard deviation) ของตัวอย่างฟิเจอร์ก่อนและหลังการทำสเกล	29
รูปภาพที่ 59 แสดงข้อมูลการปรับแต่ง Parameters ของ Logistic Regression	31
รูปภาพที่ 60 แสดงข้อมูลการปรับแต่ง RapidMiner สำหรับ Logistic Regression ใน Cross-Validation	31
รูปภาพที่ 61 แสดงข้อมูลการปรับแต่ง Parameters ของ Random Forest	32
รูปภาพที่ 62 แสดงข้อมูลการปรับแต่ง RapidMiner สำหรับ Random Forest ใน Cross-Validation	32
รูปภาพที่ 63 แสดงข้อมูลการปรับแต่ง Parameters ของ Neural Network	33
รูปภาพที่ 64 แสดงข้อมูลการปรับแต่ง RapidMiner สำหรับ Neural Network ใน Cross-Validation	33
รูปภาพที่ 65 แสดงข้อมูลการปรับแต่ง Parameters ของ Loop Parameter	34
รูปภาพที่ 66 แสดงข้อมูลการปรับแต่ง RapidMiner สำหรับ Neural Network ใน Loop Parameter	34
รูปภาพที่ 67 แสดงข้อมูลการปรับแต่ง Parameters ของ Log	34
รูปภาพที่ 68 - 71 การเปลี่ยนข้อมูลคุณลักษณะเป็น categorical	35
รูปภาพที่ 72 - 75 แสดงชุดข้อมูลหลังจากแปลง Categorical	36
รูปภาพที่ 76 - 77 แสดงโค้ด Association Rule	37
รูปภาพที่ 78 แสดงข้อมูล Performance ของ Logistic Regression	38
รูปภาพที่ 79 แสดงข้อมูล Performance ของ Random Forest	39
รูปภาพที่ 80 แสดงข้อมูล Performance ของ Neural Network	39
รูปภาพที่ 81 แสดงข้อมูลผลลัพธ์ของ K-Means	40
รูปภาพที่ 82 แสดงข้อมูลผลลัพธ์ของ Association Rules	41
รูปภาพที่ 83 แสดงจำนวนพนักงานในแต่ละคลัสเตอร์ของ K-Means	43
รูปภาพที่ 84 แสดงกราฟเส้นของค่าเฉลี่ยมาตรฐาน (standardized mean) ของแต่ละฟิเจอร์ในแต่ละคลัสเตอร์	44
รูปภาพที่ 85 แสดงกราฟจำนวน Attrition ในแต่ละคลัสเตอร์	45

สารบัญตาราง

ตาราง	หน้า
ตารางที่ 1 แผนการดำเนินงาน	2
ตารางที่ 2 รายละเอียดคุณลักษณะของข้อมูล	8
ตารางที่ 3 ผลลัพธ์การทำงานของ Classification Models	42
ตารางที่ 4 กฎความสัมพันธ์ที่สัมพันธ์กับการลาออกของพนักงาน	46
ตารางที่ 5 ตารางสรุปคลัสเตอร์	49

บทที่ 1

การทำความเข้าใจปัญหา (Problem Understanding)

1.1 ความเป็นมาและความสำคัญของปัญหา (Introduction and Problem Statement)

ในยุคปัจจุบันที่โลกธุรกิจมีการเปลี่ยนแปลงอย่างรวดเร็ว การแข่งขันทางเศรษฐกิจที่สูงขึ้นควบคู่ไปกับความคาดหวังของพนักงานที่เปลี่ยนแปลงไป ส่งผลให้องค์กรต่าง ๆ ต้องเผชิญกับความท้าทายในการรักษาพนักงานที่มีความสามารถและศักยภาพให้อยู่กับองค์กรในระยะยาว โดยเฉพาะอย่างยิ่งในอุตสาหกรรมที่ต้องพึ่งพาทักษะเฉพาะหรือบุคลากรที่ผ่านการฝึกอบรมเฉพาะทาง การสูญเสียพนักงานที่มีคุณค่าไม่เพียงแต่ส่งผลต่อการทำงานภายในทีม แต่ยังส่งผลกระทบต่อประสิทธิภาพโดยรวมขององค์กร

“การลาออกของพนักงาน” (Employee Attrition) ถือเป็นหนึ่งในปัญหาหลักที่หลายองค์กรต้องเผชิญอย่างต่อเนื่อง ไม่ว่าจะเป็นการลาออกโดยสมัครใจ (Voluntary Turnover) หรือการลาออกโดยไม่สมัครใจ (Involuntary Turnover) การสูญเสียทรัพยากรบุคคลไม่เพียงสร้างภาระในการสรรหาและฝึกอบรมพนักงานใหม่เท่านั้น แต่ยังเพิ่มต้นทุนทางตรงและทางอ้อม รวมถึงสร้างความไม่ต่อเนื่องในการดำเนินงาน ความเสียหายต่อวัฒนธรรมองค์กร และอาจทำให้พนักงานที่ยังอยู่รู้สึกไม่มั่นคงในหน้าที่การงานของตนเอง

การทำความเข้าใจปัจจัยที่ส่งผลต่อการตัดสินใจลาออก จึงมีความสำคัญอย่างยิ่ง โดยเฉพาะในองค์กรที่มีพนักงานจำนวนมากและความหลากหลายในมิติของงาน ระดับเงินเดือน หรือประสบการณ์ การใช้ข้อมูลที่มีอยู่ในการวิเคราะห์และพยากรณ์แนวโน้มการลาออกสามารถช่วยให้องค์กรปรับตัวเชิงกลยุทธ์ได้ทันก่อนที่จะเกิดปัญหาจริง เช่น การปรับปรุงนโยบายด้านสวัสดิการ การพัฒนาผู้บริหารระดับกลาง การสร้างเส้นทางความก้าวหน้าในสายงาน (Career Path) และการดูแล Work-Life Balance อย่างเป็นระบบ

ดังนั้นทางผู้จัดทำจึงต้องการศึกษาปัจจัยที่ส่งผลต่อการลาออกของพนักงาน โดยมีเป้าหมายเพื่อให้สามารถใช้ข้อมูลที่ได้ไปสนับสนุนการวางแผนเชิงกลยุทธ์ของฝ่ายทรัพยากรบุคคล ช่วยลดอัตราการลาออก และรักษาบุคลากรที่มีคุณภาพให้อยู่กับองค์กรได้อย่างยั่งยืน นอกจากนี้ยังเป็นการส่งเสริมการสร้างวัฒนธรรมองค์กรที่มั่นคง และมุ่งสู่การเป็น “องค์กรที่คนอยากทำงานด้วย” ในระยะยาว

1.2 วัตถุประสงค์ (Objectives)

- 1.2.1 เพื่อวิเคราะห์ข้อมูลพนักงานเพื่อเข้าใจแนวโน้มและรูปแบบของการลาออก
- 1.2.2 เพื่อพัฒนาแบบจำลอง Machine Learning ในการพยากรณ์ความเสี่ยงในการลาออก
- 1.2.3 เพื่อระบุปัจจัยสำคัญที่ส่งผลต่อการตัดสินใจลาออก
- 1.2.4 เพื่อจัดทำแดชบอร์ดและรายงานสรุปผลสำหรับการใช้งานจริงโดยฝ่าย HR และผู้บริหาร

1.3 ประโยชน์ (Benefaction)

- 1.3.1 ช่วยให้องค์กรสามารถคาดการณ์แนวโน้มการลาออกของพนักงานได้ล่วงหน้า
- 1.3.2 ช่วยให้ฝ่าย HR วางแผนกลยุทธ์ในการรักษาพนักงานได้อย่างมีประสิทธิภาพ
- 1.3.3 ลดต้นทุนในการสรรหาและฝึกอบรมพนักงานใหม่
- 1.3.4 สนับสนุนการตัดสินใจด้วยข้อมูล (Data-Driven Decision Making) เพื่อปรับปรุงสภาพแวดล้อมในการทำงาน

1.4 กรอบโครงการ (Project Framework)

โครงการนี้ใช้ชุดข้อมูล Employee Attrition Dataset จาก Kaggle.com โดยมีเป้าหมายในการวิเคราะห์และพยากรณ์แนวโน้มการลาออกของพนักงาน โดยดำเนินงานทั้งหมดผ่านการเขียนโปรแกรมใน VS Code ด้วยภาษา Python ประกอบด้วยการเตรียมข้อมูลให้พร้อมใช้งาน การวิเคราะห์ข้อมูลเบื้องต้นเพื่อค้นหาความสัมพันธ์ของตัวแปรสำคัญ และการพัฒนาแบบจำลองด้วยอัลกอริทึม Logistic Regression, Random Forest, Neural Network, K-Mean และ Association Rule จากนั้นสรุปผลการวิเคราะห์และประสิทธิภาพของแต่ละโมเดล พร้อมจัดทำข้อเสนอแนะเชิงกลยุทธ์เพื่อนำไปประยุกต์ใช้ในองค์กรผ่านการทำ Visualization

1.5 แผนการดำเนินการ (Action Plan)

ระยะเวลาสำหรับการดำเนินโครงการอยู่ระหว่างเดือนมกราคม - เมษายน พ.ศ. 2568 โดยมีรายละเอียดดังนี้

ตารางที่ 1 แผนการดำเนินงาน

ระยะเวลา/การดำเนินงาน	ม.ค.	ก.พ.	มี.ค.	เม.ย.
บทที่ 1 การทำความเข้าใจปัญหา				
บทที่ 2 การทำความเข้าใจ ข้อมูล				
บทที่ 3 การเตรียมข้อมูล				
บทที่ 4 การสร้าง แบบจำลองข้อมูล				
บทที่ 5 การสรุป อภิปรายผลและข้อเสนอแนะ				
ทำ Visualization				

1.6 การทบทวนวรรณกรรม (Literature Reviews)

การทบทวนวรรณกรรมเป็นขั้นตอนสำคัญในการศึกษาค้นคว้าเกี่ยวกับแนวคิด ทฤษฎี และผลงานวิจัยที่เกี่ยวข้องกับการวิเคราะห์การลาออกของพนักงาน โดยเฉพาะอย่างยิ่งเมื่อโครงการนี้นำเทคนิคเหมืองข้อมูล (Data Mining) และการเรียนรู้ของเครื่อง (Machine Learning) เข้ามาประยุกต์ใช้เพื่อพยากรณ์แนวโน้มของพฤติกรรมพนักงาน การศึกษาวรรณกรรมที่เกี่ยวข้องจะช่วยให้เข้าใจลักษณะของปัญหา วิธีการแก้ไข และเลือกเทคนิคที่เหมาะสมที่สุด โดยสามารถจำแนกเป็นหัวข้อสำคัญได้ดังนี้

1.6.1 การลาออกของพนักงาน

การลาออกของพนักงาน หมายถึง การที่พนักงานสิ้นสุดความสัมพันธ์กับองค์กร ไม่ว่าจะโดยความสมัครใจ (เช่น เปลี่ยนงาน หรือลาออกด้วยเหตุผลส่วนตัว) หรือไม่สมัครใจ (เช่น ถูกเลิกจ้างหรือยุบแผนก) ซึ่งถือเป็นหนึ่งในปัญหาสำคัญด้านทรัพยากรบุคคล เนื่องจากส่งผลกระทบต่อตรงทั้งในแง่ของต้นทุนการดำเนินงาน และผลกระทบต่อประสิทธิภาพของทีม เช่น การต้องสรรหาและฝึกอบรมพนักงานใหม่ การหยุดชะงักของงาน และการลดลงของขวัญกำลังใจของพนักงานที่ยังอยู่ การวิเคราะห์สาเหตุและปัจจัยของการลาออกจึงกลายเป็นหัวใจสำคัญในการวางแผนกลยุทธ์ขององค์กรในระยะยาว

1.6.2 ปัจจัยที่ส่งผลต่อการลาออก

จากงานศึกษาหลายฉบับพบว่า การลาออกของพนักงานมักเกี่ยวข้องกับหลายปัจจัยผสมกัน ทั้งเชิงประชากร (Demographic) และเชิงพฤติกรรม เช่น

- อายุ: พนักงานที่อายุน้อยมักเปลี่ยนงานบ่อย ในขณะที่ผู้ที่มีอายุมากอาจลาออกเนื่องจากใกล้เกษียณ
- ระดับรายได้: พนักงานที่รู้สึกว่ารายได้ไม่เหมาะสมกับปริมาณงานหรือทักษะ อาจมีแนวโน้มลาออกสูง
- ระยะเวลาทำงาน: พนักงานที่ทำงานนานมักมีความผูกพันต่อองค์กร แต่อาจรู้สึกถึงการหยุดชะงักของโอกาสก้าวหน้า
- ตำแหน่งงานและหน่วยงาน: บางตำแหน่งมีความเสี่ยงในการลาออกสูง เช่น Call Center หรือ Sales
- ความพึงพอใจในงาน: พนักงานที่ไม่พึงพอใจกับหัวหน้างาน วัฒนธรรมองค์กร หรือชั่วโมงทำงาน อาจพิจารณาออกจากรางานได้ง่ายขึ้น

การวิเคราะห์ข้อมูลหลายมิติพร้อมกันทำให้สามารถพยากรณ์ความเสี่ยงการลาออกได้อย่างมีประสิทธิภาพ


1.6.3 เทคนิคเหมืองข้อมูล (Data Mining Techniques)

เทคนิคเหมืองข้อมูล (Data Mining) คือกระบวนการวิเคราะห์ข้อมูลจำนวนมากเพื่อค้นหารูปแบบ แนวโน้ม หรือความสัมพันธ์ที่ซ่อนอยู่ภายในข้อมูล โดยใช้เครื่องมือทางสถิติและอัลกอริทึมของคอมพิวเตอร์เข้ามาช่วย การประมวลผลข้อมูลด้วยเทคนิคเหมืองข้อมูลช่วยให้สามารถดึงข้อมูลที่มีคุณค่ามาใช้ในการตัดสินใจ หรือพยากรณ์สิ่งที่อาจเกิดขึ้นในอนาคต

กระบวนการเหมืองข้อมูลประกอบด้วยหลายขั้นตอน ได้แก่ การทำความเข้าใจข้อมูล การเตรียมข้อมูลให้เหมาะสม เช่น การลบข้อมูลที่ไม่จำเป็น หรือการแปลงค่าข้อมูล และการเลือกใช้เทคนิควิเคราะห์ที่เหมาะสมกับปัญหา เช่น การจำแนกประเภท การจัดกลุ่ม หรือการพยากรณ์ นอกจากนี้ยังต้องมีการประเมินผลโมเดลเพื่อให้มั่นใจว่าได้ผลลัพธ์ที่น่าเชื่อถือและสามารถนำไปใช้ได้จริง

1.6.3.1 Logistic Regression


Logistic Regression เป็นเทคนิคทางสถิติที่ใช้สำหรับการจำแนกประเภทข้อมูลซึ่งผลลัพธ์อยู่ในรูปแบบของค่าทางตรรกะหรือค่าทางเลือก เช่น ใช่/ไม่ใช่ หรือ 0/1 โดยโมเดลจะประเมินความน่าจะเป็นที่ตัวแปรตามจะเป็นผลลัพธ์ใดผลลัพธ์หนึ่ง ตามค่าของตัวแปรต้นที่กำหนด ซึ่งโมเดลจะสร้างฟังก์ชันจากการรวมเชิงเส้นของตัวแปรต้น ($y=mx+c$) จากนั้นแปลงผลลัพธ์ผ่านฟังก์ชัน Sigmoid เพื่อให้ได้ค่าความน่าจะเป็นที่อยู่ระหว่าง 0 ถึง 1 การตัดสินใจผลลัพธ์สุดท้ายจะกระทำโดยกำหนดค่าขีดจำกัด (threshold) เช่น 0.5 หากค่าความน่าจะเป็นมากกว่าค่านี้ จะจัดเป็นกลุ่มหนึ่ง หากน้อยกว่าจะจัดเป็นอีกกลุ่มหนึ่ง จุดเด่นของ Logistic Regression คือการที่สามารถตีความค่าสัมประสิทธิ์ของตัวแปรได้โดยตรง โดยค่าสัมประสิทธิ์ที่เป็นบวกแสดงถึงความสัมพันธ์เชิงบวกกับผลลัพธ์ และค่าสัมประสิทธิ์ที่เป็นลบแสดงถึงความสัมพันธ์เชิงลบ ดังภาพที่ 1



รูปภาพที่ 1 กราฟ Logistic Regression

1.6.3.4 K-Means Clustering

K-Means Clustering เป็นเทคนิคการจัดกลุ่มแบบไม่ต้องใช้ตัวแปรตาม (unsupervised learning) ซึ่งใช้วิธีแบ่งข้อมูลออกเป็นกลุ่มย่อยตามความคล้ายคลึงกันของลักษณะข้อมูล โดยเริ่มต้นจากการกำหนดจำนวนกลุ่ม (k) ที่ต้องการ จากนั้นสุ่มตำแหน่งของจุดศูนย์กลางของแต่ละกลุ่ม (centroids) และจัดข้อมูลแต่ละจุดให้อยู่ในกลุ่มที่มีศูนย์กลางใกล้ที่สุด หลังจากจัดกลุ่มเรียบร้อยแล้ว จะมีการคำนวณศูนย์กลางใหม่ของแต่ละกลุ่มและทำซ้ำกระบวนการไปเรื่อย ๆ จนกว่าศูนย์กลางจะไม่เปลี่ยนแปลงอย่างมีนัยสำคัญ ดังรูปภาพที่ 4




รูปภาพที่ 4 การทำงานของ K-Means Clustering

1.6.3.5 Association Rule

Association Rule คือเทคนิคที่ใช้ในการค้นหาความสัมพันธ์ระหว่างรายการหรือเหตุการณ์ภายในชุดข้อมูล โดยเฉพาะในกรณีที่ข้อมูลเป็นกลุ่มของรายการที่เกิดขึ้นร่วมกันเป็นประจำ เทคนิคนี้จะสร้างกฎความสัมพันธ์ที่มีรูปแบบทั่วไปในลักษณะ “ถ้า A แล้ว B” โดยการประเมินคุณภาพของกฎจะอาศัยดัชนีสำคัญ 3 ค่า ได้แก่ Support ซึ่งแสดงถึงความถี่ของการเกิดกฎในชุดข้อมูล, Confidence ซึ่งแสดงถึงความน่าจะเป็นที่เหตุการณ์ปลายทางจะเกิดขึ้นเมื่อเหตุการณ์ต้นทางเกิดขึ้น และ Lift ซึ่งใช้วัดระดับความสัมพันธ์ระหว่างเหตุการณ์สองรายการว่ามีความสัมพันธ์มากกว่าการเกิดขึ้นแบบสุ่มหรือไม่

Items already in basket + Available items → Item likely to be added




รูปภาพที่ 5 ตัวอย่าง Association Rule

1.6.4 การจัดการข้อมูลไม่สมดุล (Imbalanced Data)

ข้อมูลไม่สมดุล (Imbalanced Data) คือสถานะที่กลุ่มของข้อมูลเป้าหมายในชุดข้อมูลมีสัดส่วนไม่เท่ากันอย่างมาก เช่น กลุ่มหนึ่งมีจำนวนตัวอย่างมาก ในขณะที่อีกกลุ่มมีจำนวนตัวอย่างน้อยมาก ความไม่สมดุลนี้ส่งผลกระทบต่อประสิทธิภาพของการเรียนรู้ของโมเดล เนื่องจากอัลกอริทึมส่วนใหญ่มีแนวโน้มที่จะให้ความสำคัญกับกลุ่มที่มีจำนวนมาก และละเลยกลุ่มที่มีจำนวนน้อย ส่งผลให้เกิดอคติในการทำนายและลดทอนความแม่นยำโดยเฉพาะในกลุ่มเป้าหมายที่สำคัญ

เพื่อแก้ไขปัญหาจึงต้องใช้เทคนิคหลายรูปแบบ เช่น Oversampling ซึ่งเป็นการเพิ่มจำนวนตัวอย่างของกลุ่มที่มีน้อยให้มากขึ้น โดยอาจคัดลอกข้อมูลเดิมหรือใช้วิธีการสังเคราะห์ข้อมูลใหม่แบบเทียม เช่น SMOTE (Synthetic Minority Over-sampling Technique) ซึ่งจะสร้างตัวอย่างใหม่จากจุดข้อมูลที่มีอยู่โดยใช้วิธีทางเรขาคณิตเพื่อสร้างตัวแปรเฉลี่ยในระยะใกล้ นอกจากนี้ยังมีเทคนิค Under sampling ที่ลดจำนวนตัวอย่างจากกลุ่มที่มีมาก เพื่อให้เกิดความสมดุลเชิงสัดส่วนระหว่างกลุ่มต่าง ๆ



รูปภาพที่ 6 ตัวอย่าง Imbalanced Data

1.6.5 การประเมินผลโมเดล (Model Evaluation Metrics)

การประเมินประสิทธิภาพของโมเดลการเรียนรู้ของเครื่องเป็นขั้นตอนสำคัญในการวัดว่าแบบจำลองสามารถทำงานได้ดีเพียงใด โดยเฉพาะในการจำแนกประเภทหรือการพยากรณ์ค่าผลลัพธ์ ตัวชี้วัดพื้นฐานที่นิยมใช้ได้แก่ Accuracy ซึ่งคำนวณจากสัดส่วนของการทำนายที่ถูกต้องต่อจำนวนข้อมูลทั้งหมด อย่างไรก็ตาม ค่านี้อาจให้ภาพลวงตาเมื่อชุดข้อมูลมีการกระจายไม่สมดุล จึงต้องพิจารณาตัวชี้วัดอื่นร่วมด้วย เช่น Precision ซึ่งวัดสัดส่วนของผลลัพธ์ที่ทำนายว่าอยู่ในกลุ่มเป้าหมายแล้วเป็นจริง, Recall ซึ่งวัดสัดส่วนของกลุ่มเป้าหมายจริงที่ถูกทำนายได้ถูกต้อง และ F1-score ซึ่งเป็นค่าเฉลี่ยของ Precision และ Recall ใช้เพื่อชี้วัดประสิทธิภาพโดยรวมอย่างสมดุล

		Actual Values	
		Positive (1)	Negative (0)
Predicted Values	Positive (1)	TP	FP
	Negative (0)	FN	TN

รูปภาพที่ 7 ตาราง Evaluation Metrics

บทที่ 2

การทำความเข้าใจข้อมูล (Data Understanding)

2.1 การอธิบายข้อมูล (Data Description)

ข้อมูลที่ใช้ในการวิเคราะห์ในโครงการนี้คือ Employee Attrition Prediction Dataset ซึ่งประกอบด้วยข้อมูลพนักงานจำนวน 10,000 รายการ โดยมีตัวแปรทั้งหมด 26 ตัวแปร ที่ครอบคลุมทั้งข้อมูลส่วนบุคคล ข้อมูลงาน ความพึงพอใจ และประสิทธิภาพในการทำงานของพนักงานแต่ละคน ซึ่งได้อธิบายความหมายของแต่ละคุณลักษณะลงในตารางที่ 2 โดยแสดงรายละเอียดคุณลักษณะทั้งหมดของชุดข้อมูล

Employee_ID	Age	Gender	Marital_Status	Department	Job_Role	Job_Level	Monthly_Income	Hourly_Rate	Years_at_Company	Years_in_Current_Role				
0	1	58	Male	Single	Finance	Manager	5	7332	81	24	12			
1	2	48	Female	Divorced	HR	Assistant	4	6069	55	18	7			
2	3	34	Female	Married	Marketing	Manager	4	11485	65	6	4			
3	4	27	Female	Divorced	HR	Manager	4	18707	28	12	9			
4	5	40	Male	Married	HR	Analyst	1	16398	92	3	9			
Years_Since_Last_Promotion			Work_Life_Balance		Job_Satisfaction		Performance_Rating		Training_Hours_Last_Year		Overtime	Project_Count		
			3		1		3		2		74	No	9	
			5		1		2		2		24	Yes	9	
			3		4		5		1		63	Yes	3	
			1		1		1		2		4	No	9	
			1		3		4		3		62	No	1	
Average_Hours_Worked_Per_Week			Absenteeism		Work_Environment_Satisfaction			Relationship_with_Manager		Job_Involvement		Distance_From_Home		
			48		16			4			1		1	49
			57		10			4			1		1	25
			55		1			1			4		3	21
			53		2			3			4		1	46
			54		11			1			1		1	43
					Number_of_Companies_Worked		Attrition							
							3		No					
							1		No					
							1		Yes					
							2		No					
							4		No					

รูปภาพที่ 8,9,10,11แสดงรายละเอียดของข้อมูลเบื้องต้น

2.1.1 ตารางที่ 2 รายละเอียดคุณลักษณะของข้อมูล

ชื่อ	ประเภท	ความหมาย
Employee_ID	Nominal	รหัสประจำตัวพนักงาน
Age	Discrete	อายุของพนักงาน
Gender	Nominal	เพศของพนักงาน
Marital_Status	Nominal	สถานภาพสมรส
Department	Nominal	แผนกที่พนักงานสังกัด
Job_Role	Nominal	ตำแหน่งงานของพนักงาน

Job_Level	Ordinal	ระดับตำแหน่งงานในองค์กร
Monthly_Income	Continuous	รายได้ต่อเดือนของพนักงาน
Hourly_Rate	Discrete	ค่าจ้างต่อชั่วโมง (สำหรับพนักงานที่รับราย ชั่วโมง)
Years_at_Company	Discrete	จำนวนปีที่พนักงานทำงานอยู่กับบริษัท
Years_in_Current_Role	Discrete	จำนวนปีที่พนักงานอยู่ในตำแหน่งปัจจุบัน
Years_Since_Last_Promotion	Discrete	จำนวนปีนับจากที่พนักงานได้รับการเลื่อน ตำแหน่งครั้งล่าสุด
Work_Life_Balance	Ordinal	คะแนนความสมดุลระหว่างชีวิตส่วนตัวกับ การทำงาน
Job_Satisfaction	Ordinal	คะแนนความพึงพอใจในงาน
Performance_Rating	Ordinal	คะแนนการประเมินผลการปฏิบัติงาน
Training_Hours_Last_Year	Discrete	จำนวนชั่วโมงที่เข้ารับการฝึกอบรมในปีที่ ผ่านมา
Overtime	Nominal	พนักงานทำงานล่วงเวลาหรือไม่
Project_Count	Discrete	จำนวนโปรเจกต์ที่พนักงานรับผิดชอบใน ช่วงเวลาหนึ่ง
Average_Hours_Worked_Per_Week	Continuous	จำนวนชั่วโมงทำงานเฉลี่ยต่อสัปดาห์
Absenteeism	Discrete	จำนวนวันที่พนักงานขาดงานในปีที่ผ่านมา
Work_Environment_Satisfaction	Ordinal	คะแนนความพึงพอใจต่อสภาพแวดล้อม การทำงาน
Relationship_with_Manager	Ordinal	คะแนนความสัมพันธ์กับผู้จัดการ
Job_Involvement	Ordinal	ระดับการมีส่วนร่วมในงาน
Distance_From_Home	Continuous	ระยะทางจากบ้านถึงที่ทำงาน (หน่วย: กิโลเมตร)
Number_of_Companies_Worked	Discrete	จำนวนบริษัทที่พนักงานเคยทำงาน
Attrition	Nominal	พนักงานลาออกหรือไม่

2.2 การสำรวจข้อมูล (Data Exploration)

เพื่อให้เข้าใจข้อมูลเชิงลึกมากยิ่งขึ้น ก่อนเข้าสู่การวิเคราะห์หรือพัฒนาแบบจำลองใด ๆ จำเป็นต้องมีการสำรวจข้อมูลเบื้องต้น (Exploratory Data Analysis: EDA) เพื่อให้เข้าใจถึงลักษณะทั่วไปของข้อมูล แนวโน้ม ความผิดปกติ ความสัมพันธ์ระหว่างตัวแปร และลักษณะการกระจายของข้อมูลต่าง ๆ

ในการสำรวจข้อมูลครั้งนี้ ผู้จัดทำได้นำเข้าสู่ชุดข้อมูลเข้าสู่โปรแกรม Python โดยใช้เครื่องมือ Visual Studio Code (VS Code) ซึ่งเป็นสภาพแวดล้อมที่เอื้อต่อการวิเคราะห์ข้อมูล และสามารถสร้างภาพข้อมูลได้อย่างยืดหยุ่น โดยการวิเคราะห์ในส่วนนี้จะแบ่งออกเป็นหลายหัวข้อย่อย ซึ่งเริ่มจากการสรุปสถิติเบื้องต้นของตัวแปรในชุดข้อมูล

2.2.1 สำรวจประเภทของข้อมูล

Data types of each attribute:			
Employee_ID	int64	Job_Satisfaction	int64
Age	int64	Performance_Rating	int64
Gender	object	Training_Hours_Last_Year	int64
Marital_Status	object	Overtime	object
Department	object	Project_Count	int64
Job_Role	object	Average_Hours_Worked_Per_Week	int64
Job_Level	int64	Absenteeism	int64
Monthly_Income	int64	Work_Environment_Satisfaction	int64
Hourly_Rate	int64	Relationship_with_Manager	int64
Years_at_Company	int64	Job_Involvement	int64
Years_in_Current_Role	int64	Distance_From_Home	int64
Years_Since_Last_Promotion	int64	Number_of_Companies_Worked	int64
Work_Life_Balance	int64	Attrition	object

รูปภาพที่ 12,13 แสดงประเภทของข้อมูล

2.2.2 การสำรวจข้อมูลสถิติเชิงพรรณนา (Summary Statistics)

Descriptive statistics for numerical attributes:					
	Employee_ID	Age	Job_Level	Monthly_Income	Hourly_Rate
count	10000.000000	10000.000000	10000.000000	10000.000000	10000.000000
mean	5000.500000	39.561800	2.990890	11436.716700	57.032300
std	2886.895688	11.454986	1.418643	4926.528302	24.783261
min	1.000000	20.000000	1.000000	3000.000000	15.000000
25%	2500.750000	30.000000	2.000000	7182.500000	36.000000
50%	5000.500000	40.000000	3.000000	11401.500000	57.000000
75%	7500.250000	49.000000	4.000000	15679.500000	78.000000
max	10000.000000	59.000000	5.000000	19999.000000	99.000000

	Work_Life_Balance	Job_Satisfaction	Performance_Rating
count	10000.000000	10000.000000	10000.000000
mean	2.502400	3.038000	2.507700
std	1.112348	1.414764	1.120833
min	1.000000	1.000000	1.000000
25%	2.000000	2.000000	2.000000
50%	2.000000	3.000000	3.000000
75%	3.000000	4.000000	4.000000
max	4.000000	5.000000	4.000000

	Years_at_Company	Years_in_Current_Role	Years_Since_Last_Promotion
count	10000.000000	10000.000000	10000.000000
mean	14.936200	7.451300	4.471900
std	8.431657	4.042903	2.801617
min	1.000000	1.000000	0.000000
25%	8.000000	4.000000	2.000000
50%	15.000000	7.000000	4.000000
75%	22.000000	11.000000	7.000000
max	29.000000	14.000000	9.000000

	Training_Hours_Last_Year	Project_Count	Average_Hours_Worked_Per_Week
count	10000.000000	10000.000000	10000.000000
mean	49.580000	4.984400	44.473500
std	28.801393	2.580043	8.611662
min	0.000000	1.000000	30.000000
25%	25.000000	3.000000	37.000000
50%	49.000000	5.000000	45.000000
75%	75.000000	7.000000	52.000000
max	99.000000	9.000000	59.000000

	Absenteeism	Work_Environment_Satisfaction	Relationship_with_Manager
count	10000.000000	10000.000000	10000.000000
mean	9.410200	2.493100	2.491400
std	5.760335	1.120927	1.115101
min	0.000000	1.000000	1.000000
25%	4.000000	1.000000	1.000000
50%	9.000000	2.000000	2.000000
75%	14.000000	4.000000	3.000000
max	19.000000	4.000000	4.000000

	Job_Involvement	Distance_From_Home	Number_of_Companies_Worked
count	10000.000000	10000.000000	10000.000000
mean	2.505400	25.272000	2.516600
std	1.116018	14.219474	1.113934
min	1.000000	1.000000	1.000000
25%	2.000000	13.000000	2.000000
50%	3.000000	25.000000	2.000000
75%	3.000000	37.000000	4.000000
max	4.000000	49.000000	4.000000

รูปภาพที่ 14,15,16 ค่าต่าง ๆ ของแต่ละ Numerical Attributes

Descriptive statistics for categorical attributes:						
	Gender	Marital_Status	Department	Job_Role	Overtime	Attrition
count	10000	10000	10000	10000	10000	10000
unique	2	3	5	4	2	2
top	Female	Married	Marketing	Analyst	No	No
freq	5042	3375	2133	2572	5103	8003

รูปภาพที่ 17 ค่าต่าง ๆ ของแต่ละ Categorical Attributes

ในการวิเคราะห์ข้อมูลเบื้องต้น ได้ทำการสรุปสถิติเชิงพรรณนา (Descriptive Statistics) ของตัวแปรทั้งหมดในชุดข้อมูล เพื่อทำความเข้าใจลักษณะการกระจายตัว แนวโน้ม และความหลากหลายของข้อมูล ซึ่งมีทั้งตัวแปรเชิงตัวเลข (Numerical Attributes) และตัวแปรเชิงหมวดหมู่ (Categorical Attributes)

จากการวิเคราะห์ข้อมูลเชิงตัวเลข (แสดงในภาพที่ 14–16) พบว่าชุดข้อมูลมีจำนวนพนักงานทั้งหมด 10,000 คน โดยพนักงานมีอายุเฉลี่ยอยู่ที่ ประมาณ 39.6 ปี มีอายุต่ำสุดที่ 20 ปี และสูงสุดที่ 59 ปี ข้อมูลนี้แสดงให้เห็นถึงความหลากหลายทางช่วงวัยของพนักงานภายในองค์กร ในขณะที่ระดับตำแหน่ง (Job_Level) มีค่ากลางอยู่ที่ระดับ 3 จากทั้งหมด 5 ระดับ สะท้อนให้เห็นถึงการกระจายของระดับตำแหน่งในองค์กรที่ค่อนข้างสม่ำเสมอ

ด้านรายได้ (Monthly_Income) พบว่าพนักงานมีรายได้เฉลี่ยอยู่ที่ 11,436.72 บาทต่อเดือน โดยมีค่าต่ำสุด 3,000 บาท และสูงสุด 19,999 บาท ซึ่งแสดงถึงความแตกต่างของรายได้ตามตำแหน่งงานหรือประสบการณ์ ส่วนอัตราค่าจ้างรายชั่วโมง (Hourly_Rate) เฉลี่ยอยู่ที่ 57.03 บาทต่อชั่วโมง ซึ่งครอบคลุมตั้งแต่ 15 บาท ไปจนถึง 99 บาท โดยค่ากลาง (Median) อยู่ที่ 57 บาท สะท้อนให้เห็นว่าองค์กรมีทั้งพนักงานประจำและรายชั่วโมงที่หลากหลาย

ในแง่ของประสบการณ์ พนักงานมีอายุงานในองค์กรเฉลี่ย ประมาณ 15 ปี โดยมีผู้ที่ทำงานมานานถึง 29 ปี และอยู่ในตำแหน่งปัจจุบันเฉลี่ยประมาณ 7.45 ปี ระยะเวลาตั้งแต่การเลื่อนตำแหน่งล่าสุดอยู่ที่ 4.47 ปี โดยบางคนยังไม่เคยได้รับการเลื่อนตำแหน่งเลย (0 ปี) ข้อมูลดังกล่าวสามารถนำไปวิเคราะห์ร่วมกับความพึงพอใจในงาน เพื่อหาความสัมพันธ์ระหว่างการเติบโตในสายงานกับแนวโน้มการลาออก

เมื่อพิจารณาด้านความพึงพอใจและการประเมินผลงาน พบว่าพนักงานมี Job_Satisfaction เฉลี่ยอยู่ที่ 3.04 จาก 5 ซึ่งอยู่ในระดับกลาง ขณะที่ Performance_Rating เฉลี่ยอยู่ที่ 2.51 และ Job_Involvement เฉลี่ยอยู่ที่ 2.51 เช่นกัน บ่งชี้ว่าพนักงานส่วนใหญ่มีส่วนร่วมในงานและผลงานอยู่ในระดับปานกลาง คะแนน Work_Life_Balance เฉลี่ยอยู่ที่ 2.5 จาก 4 ซึ่งสะท้อนให้เห็นว่าสมดุลระหว่างงานและชีวิตส่วนตัวยังไม่ถึงจุดที่น่าพึงพอใจนัก ข้อมูลนี้สามารถนำไปวิเคราะห์ร่วมกับตัวแปรเป้าหมาย (Attrition) ได้เพื่อประเมินว่าส่งผลต่อการลาออกหรือไม่

ในด้านพฤติกรรมการทำงาน พบว่าพนักงานมีชั่วโมงการทำงานเฉลี่ยต่อสัปดาห์อยู่ที่ 44.47 ชั่วโมง และมีจำนวนโปรเจกต์ที่ดูแลเฉลี่ย 5 โปรเจกต์ต่อคน นอกจากนี้ ยังพบว่าพนักงานขาดงานเฉลี่ยปีละ 9.41 วัน โดยมีสูงสุดถึง 19 วัน ซึ่งอาจบ่งชี้ถึงปัจจัยด้านสุขภาพหรือความเครียดจากการทำงาน ในส่วนของการเดินทาง ระยะทางจากบ้านถึงที่ทำงานมีค่าเฉลี่ยอยู่ที่ 25.27 กิโลเมตร โดยมีผู้ที่เดินทางไกลที่สุดถึง 49 กิโลเมตร ซึ่งอาจเป็นหนึ่งในปัจจัยที่ส่งผลต่อความเหนื่อยล้าและอัตราการลาออก


สำหรับตัวแปรเชิงหมวดหมู่ (แสดงในภาพที่ 17) พบว่าในกลุ่มตัวอย่างนี้ พนักงานเพศหญิงมีจำนวนมากกว่าคือ 5,042 คน ขณะที่เพศชายมีจำนวน 4,958 คน แสดงให้เห็นถึงความสมดุลทางเพศในองค์กร ในส่วนของสถานภาพสมรส (Marital_Status) พบว่า พนักงานที่แต่งงานแล้ว (Married) มีจำนวนมากที่สุดคือ 3,375 คน รองลงมาคือโสด (Single) และหย่าร้าง (Divorced)


จากการวิเคราะห์ข้อมูลแผนก (Department) พบว่ามีพนักงานกระจายอยู่ใน 5 แผนก โดยแผนกที่มีจำนวนพนักงานมากที่สุดคือ “Marketing” ส่วนตำแหน่งงาน (Job_Role) ที่มีมากที่สุดคือ “Analyst” ซึ่งมีจำนวน 2,572 คน ขณะที่ข้อมูลการทำงานล่วงเวลา (Overtime) พบว่า พนักงานส่วนใหญ่ ไม่ได้ทำงานล่วงเวลา (5103 คน) มากกว่าผู้ที่ทำโอที ซึ่งอาจบ่งชี้ว่านโยบายองค์กรมีการควบคุมเวลาการทำงานอย่างเหมาะสม

สุดท้าย ในตัวแปรเป้าหมาย Attrition ซึ่งระบุว่าพนักงานลาออกหรือไม่ พบว่า มีพนักงานลาออกจำนวน 1,997 คน (19.97%) และพนักงานที่ยังอยู่มีจำนวน 8,003 คน (80.03%) ข้อมูลนี้สะท้อนว่าเป็นปัญหาที่พบในอัตราที่ค่อนข้างน้อยเมื่อเทียบกับพนักงานทั้งหมด อย่างไรก็ตาม การเข้าใจปัจจัยที่ส่งผลต่อการลาออกของกลุ่มนี้ยังคงมีความสำคัญอย่างยิ่งในการวางแผนกลยุทธ์ด้านทรัพยากรบุคคลต่อไป


2.2.3 การแจกแจงของข้อมูล (Distribution of Variables)

หลังจากการสำรวจข้อมูลสถิติเชิงพรรณนาแล้ว ได้ทำการวิเคราะห์การแจกแจงของตัวแปรแต่ละตัว เพื่อดูรูปแบบของการกระจาย เช่น การกระจายของตัวแปรเป้าหมาย (Attrition) และตัวแปรอื่นที่เกี่ยวข้องทั้งเชิงปริมาณและเชิงคุณภาพ โดยใช้เครื่องมือสร้างกราฟจากไลบรารี seaborn และ matplotlib เพื่อให้เห็นภาพที่ชัดเจน ดังภาพดังนี้






รูปภาพที่ 18,19,20 แสดงการแจกแจงของข้อมูลประเภท Categorical ในแต่ละ Attributes







รูปภาพที่ 21,22,23,24,25,26,27,28,29,30 แสดงการแจกแจงของข้อมูลประเภท Numerical ในแต่ละ Attributes

ในส่วนของ ตัวแปรเชิงหมวดหมู่ ซึ่งได้แก่ Gender, Marital_Status, Department, Job_Role, Overtime และ Attrition นั้น ได้ทำการแจกแจงเพื่อดูความแตกต่างของกลุ่มที่ “ลาออก” และ “ไม่ลาออก” ดังแสดงในภาพที่ 18–20 พบว่า พนักงานที่ทำงานล่วงเวลา (Overtime = Yes) มีอัตราการลาออกสูงกว่ากลุ่มที่ไม่ทำล่วงเวลาอย่างชัดเจน ซึ่งอาจเป็นผลมาจากภาระงานที่หนักเกินไปหรือการขาดสมดุลระหว่างชีวิตกับงาน (Work-Life Balance)

สำหรับ Marital_Status พบว่า กลุ่มที่มีสถานภาพ “โสด” มีอัตราการลาออกสูงกว่ากลุ่มที่แต่งงานแล้ว ซึ่งอาจสะท้อนถึงความมั่นคงหรือแรงจูงใจในการทำงานที่แตกต่างกัน ขณะที่ Department และ Job_Role มีการกระจายที่ค่อนข้างหลากหลาย โดยเฉพาะแผนก Marketing และตำแหน่ง Analyst ซึ่งเป็นกลุ่มที่พบมากในกลุ่มที่ลาออก ทำให้สามารถนำไปวิเคราะห์ต่อได้ว่าบางสายงานอาจมีความเสี่ยงสูงกว่าค่าเฉลี่ย

ในส่วนของ ตัวแปรเชิงปริมาณ (ภาพที่ 21–30) เช่น Monthly_Income, Years_at_Company, Distance_From_Home, Age และ Job_Satisfaction ได้วิเคราะห์ผ่านกราฟ Histogram โดยแยกตามกลุ่มของ Attrition พบว่า พนักงานที่มี รายได้ต่อเดือนต่ำกว่า 8,000 บาท มีแนวโน้มที่จะลาออกมากกว่ากลุ่มที่มีรายได้สูง ซึ่งสอดคล้องกับแนวโน้มทั่วไปในงานทรัพยากรบุคคลที่ระบุว่าค่าตอบแทนเป็นหนึ่งในปัจจัยหลักของการลาออก

ในกรณีของ Years_at_Company และ Years_in_Current_Role พบว่าพนักงานที่อยู่ในองค์กรหรือในตำแหน่งงานนั้นไม่เกิน 3 ปี มักเป็นกลุ่มที่มีอัตราการลาออกสูงสุด สะท้อนให้เห็นว่าช่วงปีแรก ๆ ของการทำงานคือช่วงเวลาสำคัญที่องค์กรควรให้ความสำคัญในการสร้างแรงจูงใจและความผูกพันกับองค์กร นอกจากนี้ พนักงานที่เดินทางไกลจากบ้าน (Distance_From_Home) มากกว่า 30 กิโลเมตร มีแนวโน้มที่จะลาออกมากขึ้น ซึ่งแสดงให้เห็นว่าระยะทางก็เป็นปัจจัยที่มีผลต่อการตัดสินใจลาออก

ในด้านความรู้สึกของพนักงาน ตัวแปร Job_Satisfaction, Work_Life_Balance, และ Relationship_with_Manager แสดงให้เห็นว่าพนักงานที่ลาออกมีแนวโน้มให้คะแนนต่ำในตัวแปรเหล่านี้มากกว่ากลุ่มที่ยังอยู่ ซึ่งตอกย้ำถึงบทบาทของ “คุณภาพชีวิตในการทำงาน” และ “ความสัมพันธ์ภายในทีม” ว่าเป็นตัวแปรเชิงพฤติกรรมที่ส่งผลอย่างชัดเจนต่อการลาออก

2.3 คุณภาพข้อมูล (Verify Data quality)

ในการวิเคราะห์ข้อมูลด้วยเทคนิคเหมืองข้อมูล จำเป็นต้องมั่นใจว่าข้อมูลที่ใช้มีความถูกต้อง ครบถ้วน และน่าเชื่อถือ การประเมินคุณภาพข้อมูลในโครงการนี้พิจารณาตามกรอบ 5 มิติหลัก ได้แก่ Accuracy, Completeness, Consistency, Timeliness และ Uniqueness ซึ่งสามารถอธิบายได้ดังนี้

2.3.1 Accuracy – ความถูกต้องของข้อมูล

```
# 1. เลือกเฉพาะตัวแปรเชิงตัวเลขที่ไม่ใช่ binary
non_binary_cols = [col for col in numerical_cols if df[col].nunique() > 2]

# 2. ฟังก์ชันตรวจ outliers ด้วย IQR
def has_outliers(series):
    Q1 = series.quantile(0.25)
    Q3 = series.quantile(0.75)
    IQR = Q3 - Q1
    lower = Q1 - 1.5 * IQR
    upper = Q3 + 1.5 * IQR
    return series[(series < lower) | (series > upper)].count() > 0

for i in range(0, len(non_binary_cols), 2):
    fig, axes = plt.subplots(1, 2, figsize=(14, 5)) # 1 แถว 2 คอลัมน์


    for j in range(2):
        if i + j < len(non_binary_cols):
            col = non_binary_cols[i + j]
            status = "Outliers detected" if has_outliers(df[col]) else "No outliers"


            sns.boxplot(data=df, x=col, color="lightblue", ax=axes[j])
            axes[j].set_title(f'Boxplot: {col} • {status}')


    plt.tight_layout()
    plt.show()
```

รูปภาพที่ 31 แสดงโค้ดในการตรวจสอบ Accuracy

ในขั้นตอนการประเมินคุณภาพข้อมูลด้าน Accuracy ได้มีการตรวจสอบค่าผิดปกติ (Outliers) โดยเลือกเฉพาะตัวแปรเชิงตัวเลขที่มีค่ามากกว่า 2 ค่า (เพื่อไม่รวมตัวแปรประเภท Binary) จากนั้นใช้เทคนิค Interquartile Range (IQR) โดยกำหนดค่าต่ำสุดและสูงสุดที่ยอมรับได้จากควอร์ไทล์ที่ 1 และ 3 ตามสูตร $1.5 * IQR$ ทั้งนี้ ได้เขียนฟังก์ชัน has_outliers() เพื่อเช็คว่ามีค่าที่หลุดจากช่วงดังกล่าวหรือไม่ และนำมาใช้ในการแสดงผลผ่านกราฟ Boxplot โดยวางรูปแบบให้อยู่ในรูปแบบตาราง 1 แถว 2 คอลัมน์เพื่อเปรียบเทียบค่าของแต่ละตัวแปรได้อย่างชัดเจน พร้อมแสดงข้อความประกอบว่าในแต่ละตัวแปรมี Outliers หรือไม่ โดยมีผลลัพธ์ดังนี้







รูปภาพที่ 32,33,34,35,36,37,38,39,40,41 กราฟแสดง outlier ตัวแปรเชิงตัวเลขที่ใช้ข้อมูลแบบ Binary

ตัวอย่างกราฟ Boxplot ของแต่ละตัวแปรแสดงให้เห็นว่าไม่มีจุดข้อมูลที่หลุดออกจากขอบเขต (outliers) ตามเกณฑ์ IQR ดังปรากฏในรูปที่ 32 – 41 โดยค่าทั้งหมดอยู่ในช่วงที่เหมาะสมตามเกณฑ์ IQR ซึ่งแสดงให้เห็นว่าข้อมูลมีความสะอาด และมีความน่าเชื่อถือ

2.3.2 Completeness – ความครบถ้วนของข้อมูล

```
# -----
# 2. Completeness – ตรวจสอบค่าที่หายไป (Missing Values)
# -----
print("\n [2] Completeness: Missing Values")

missing = df.isnull().sum()
print(missing[missing > 0] if missing.sum() > 0 else "No missing (null) values found.")

# ค่าที่น่าสงสัย เช่น na, null, ?, -, n/a, none, missing
suspicious_values = ['na', 'n/a', 'null', 'none', '-', '', '?', 'missing']
for col in df.select_dtypes(include='object'):
    suspicious_count = df[col].astype(str).str.lower().isin(suspicious_values).sum()
    if suspicious_count > 0:
        print(f"Suspicious values in '{col}': {suspicious_count}")
    else:
        print(f"No suspicious strings in '{col}'")
```

รูปภาพที่ 42 แสดงโค้ดในการตรวจสอบ Completeness

เพื่อประเมินความครบถ้วนของข้อมูล (Completeness) ได้ทำการตรวจสอบค่าที่หายไป (Missing Values) โดยใช้คำสั่ง `.isnull().sum()` ซึ่งช่วยระบุจำนวนค่าที่ขาดในแต่ละคอลัมน์ ผลลัพธ์ที่ได้พบว่าไม่มีคอลัมน์ใดในชุดข้อมูลที่มีค่า null ปรากฏอยู่ อย่างไรก็ตาม เพื่อความรัดกุม ได้มีการตรวจสอบค่าที่อาจแฝงมาในรูปแบบของข้อความที่สื่อถึง Missing เช่น "na", "n/a", "null", "none", "-", "" (ค่าว่าง), "?" และ "missing" โดยตรวจสอบเฉพาะในคอลัมน์ประเภทข้อความ (object) ซึ่งผลลัพธ์หลังจากการรันโค้ดเป็นดังนี้

```
[2] Completeness: Missing Values
No missing (null) values found.
No suspicious strings in 'Gender'
No suspicious strings in 'Marital_Status'
No suspicious strings in 'Department'
No suspicious strings in 'Job_Role'
No suspicious strings in 'Overtime'
No suspicious strings in 'Attrition'
```

รูปภาพที่ 43 ผลลัพธ์การตรวจสอบ Completeness

ผลการตรวจสอบความครบถ้วนของข้อมูล (Completeness) พบว่าไม่มีค่าที่ขาดหาย (null) ในทุกคอลัมน์ และจากการตรวจสอบเพิ่มเติมในตัวแปรประเภทข้อความ ไม่พบค่าที่น่าสงสัย เช่น "na", "n/a", "null", "none" หรือ "-" ปรากฏในชุดข้อมูล

2.3.3 Consistency – ความสม่ำเสมอของรูปแบบข้อมูล

```
# -----
# 3. Consistency – ตรวจสอบค่าที่ไม่ตรงกัน/สะกดผิด
# -----
print("\n[3] Consistency: Inconsistent Categorical Values")

for col in categorical_cols:
    unique_vals = df[col].dropna().unique()
    print(f"{col} - Unique Values: {list(unique_vals)}")
```

รูปภาพที่ 44 แสดงโค้ดในการตรวจสอบ Consistency

โค้ดส่วนนี้ใช้เพื่อตรวจสอบความสอดคล้องของข้อมูลในคอลัมน์ประเภท Categorical โดยการแสดงค่าที่ไม่ซ้ำกันในแต่ละคอลัมน์ ซึ่งช่วยให้สามารถมองเห็นค่าที่สะกดต่างกันแต่มีความหมายเดียวกัน เช่น "Male", "male", "MALE" หลังจากรันโค้ดมีผลลัพธ์ดังนี้

```
[3] Consistency: Inconsistent Categorical Values
Gender - Unique Values: ['Male', 'Female']
Marital_Status - Unique Values: ['Single', 'Divorced', 'Married']
Department - Unique Values: ['Finance', 'HR', 'Marketing', 'Sales', 'IT']
Job_Role - Unique Values: ['Manager', 'Assistant', 'Analyst', 'Executive']
Overtime - Unique Values: ['No', 'Yes']
Attrition - Unique Values: ['No', 'Yes']
```

รูปภาพที่ 45 ผลลัพธ์การตรวจสอบ Consistency

จากผลการตรวจสอบความสอดคล้องของข้อมูลในรูปที่ 44 แสดงให้เห็นค่าที่ไม่ซ้ำกันในแต่ละคอลัมน์ประเภท Categorical เช่น Gender มีเพียงค่า 'Male' และ 'Female' ซึ่งไม่มีความผิดปกติด้านการสะกด คอลัมน์อื่น ๆ อย่าง Marital_Status, Department, Job_Role, Overtime และ Attrition ก็แสดงค่าที่สอดคล้องกันดี ไม่มีกรณีสะกดผิดหรือตัวพิมพ์ใหญ่-เล็กที่ไม่ตรงกัน จึงสรุปได้ว่าในขั้นตอนนี้ข้อมูลในคอลัมน์ประเภท Categorical มีความสม่ำเสมอ (Consistent)

2.3.4 Timeliness – ความทันสมัยของข้อมูล

```
# -----
# 4. Timeliness – ตรวจสอบความเป็นปัจจุบัน (if available)
# -----
print("\n[4] Timeliness: Date Validation")

# ไม่มีข้อมูลวัน/เวลาใน dataset นี้ จึงไม่สามารถวัด Timeliness ได้
print("No date/time columns present → Timeliness cannot be evaluated.")
```

รูปภาพที่ 46 แสดงโค้ดในการตรวจสอบ Timeliness

ชุดข้อมูลนี้ไม่มีคอลัมน์ที่เกี่ยวข้องกับวันหรือเวลา เช่น วันที่เริ่มงานหรือวันที่ลาออก จึงไม่สามารถประเมินคุณภาพในด้าน Timeliness ได้ ข้อมูลชุดนี้จึงเหมาะสำหรับการวิเคราะห์ภาพรวม แต่หากต้องการวิเคราะห์แนวโน้มตามช่วงเวลา อาจจำเป็นต้องมีข้อมูลวัน/เวลาเพิ่มเติม

2.3.5 Uniqueness – ความเป็นเอกลักษณ์ของข้อมูล

```
# -----
# 5. Uniqueness – ตรวจสอบค่า ID และข้อมูลซ้ำ
# -----
print("\n[5] Uniqueness: Duplicates and ID Checks")

# ตรวจสอบแถวซ้ำ
duplicates = df.duplicated().sum()
print(f"Duplicate rows: {duplicates}" if duplicates > 0 else "No duplicate rows found.")

# ตรวจสอบ Employee_ID ซ้ำ
if 'Employee_ID' in df.columns:
    unique_ids = df['Employee_ID'].nunique()
    total_ids = df.shape[0]
    if unique_ids < total_ids:
        print(f"Employee_ID not unique → {total_ids - unique_ids} duplicates found")
    else:
        print("Employee_ID is unique.")
else:
    print("Column 'Employee_ID' not found")
```

รูปภาพที่ 47 แสดงโค้ดในการตรวจสอบ Uniqueness

โค้ดส่วนนี้ใช้สำหรับตรวจสอบความไม่ซ้ำซ้อนของข้อมูล (Uniqueness) โดยแบ่งออกเป็นสองส่วนหลัก ได้แก่ การตรวจสอบแถวข้อมูลที่ซ้ำกันในทั้ง Data Frame ด้วยคำสั่ง `df.duplicated().sum()` และการตรวจสอบความไม่ซ้ำกันของรหัสพนักงาน (Employee_ID) ซึ่งควรเป็นค่าที่ไม่ซ้ำกันในแต่ละแถว หากพบว่ามี ID ซ้ำกัน จะรายงานจำนวนที่ซ้ำ แต่หากไม่พบหรือไม่มีคอลัมน์นี้ในข้อมูลระบบจะแจ้งให้ทราบ

```
[5] Uniqueness: Duplicates and ID Checks
No duplicate rows found.
Employee_ID is unique.
```

รูปภาพที่ 48 ผลลัพธ์การตรวจสอบ Uniqueness

จากผลการตรวจสอบในรูปแบบที่แสดง พบว่าไม่มีแถวข้อมูลที่ซ้ำกัน และคอลัมน์ Employee_ID ก็มีค่าที่ไม่ซ้ำกันทั้งหมด แสดงให้เห็นว่าข้อมูลมีความไม่ซ้ำซ้อน (Uniqueness) อยู่ในระดับที่ดี พร้อมสำหรับการนำไปวิเคราะห์ต่อ

บทที่ 3

การจัดเตรียมข้อมูล (Data Preparation)

หลังจากที่ได้ทำการสำรวจข้อมูลเบื้องต้น (Exploratory Data Analysis) แล้ว ขั้นตอนถัดไปคือการ จัดเตรียมข้อมูลเพื่อให้เหมาะสมสำหรับการนำไปประมวลผลด้วยเทคนิคเหมืองข้อมูล (Data Mining) ต่าง ๆ ซึ่งเป็นขั้นตอนสำคัญที่มีผลต่อความแม่นยำและประสิทธิภาพของแบบจำลอง

กระบวนการจัดเตรียมข้อมูลในบทนี้ประกอบด้วย 2 ขั้นตอนหลัก ได้แก่ การคัดเลือกข้อมูล (Feature Selection) และ การสร้างชุดข้อมูล (Data Construction) โดยรายละเอียดในแต่ละขั้นตอนมีดังนี้

3.1 การคัดเลือกข้อมูล (Feature Selection)

3.1.1 Encoding (Label + One-hot Encoding)

```
print("\n🚀 [3.1] Feature Selection ☐ Correlation with Attrition")

df_encoded = df.copy()

# Binary Encoding
if 'Attrition' in df_encoded.columns:
    df_encoded['Attrition'] = df_encoded['Attrition'].map({'Yes': 1, 'No': 0})
if 'Overtime' in df_encoded.columns:
    df_encoded['Overtime'] = df_encoded['Overtime'].map({'Yes': 1, 'No': 0})
if 'Gender' in df_encoded.columns:
    df_encoded['Gender'] = df_encoded['Gender'].map({'Male': 1, 'Female': 0})

# One-hot Encoding
df_encoded = pd.get_dummies(df_encoded, drop_first=True, dtype=int)
```

รูปภาพที่ 49 แสดงโค้ด Encoding (Label + One-hot Encoding)

เนื่องจากข้อมูลมีตัวแปรหมวดหมู่ (Categorical Variables) เช่น Gender, Marital_Status, Department ซึ่งไม่สามารถนำไปใช้โดยตรงในโมเดลที่ต้องการค่าตัวเลขได้ จึงต้องแปลงให้อยู่ในรูปแบบตัวเลข

- ตัวแปรที่มีค่าเป็น Yes/No เช่น Attrition และ Overtime ถูกแปลงเป็นค่า Binary โดย Yes = 1 และ No = 0
- ตัวแปรที่มีค่าเป็นหมวดหมู่หลายค่า เช่น Department, Job_Role ถูกแปลงด้วยเทคนิค One-hot encoding เพื่อให้แต่ละค่าถูกแทนด้วยตัวแปรแยกต่างหากและไม่มีลำดับเชิงตัวเลข

	Number_of_Companies_Worked	Attrition	Marital_Status_Married	\
0	3	0	0	
1	1	0	0	
2	1	1	1	
3	2	0	0	
4	4	0	1	

	Marital_Status_Single	Department_HR	Department_IT	Department_Marketing	\
0	1	0	0	0	
1	0	1	0	0	
2	0	0	0	1	
3	0	1	0	0	
4	0	1	0	0	

	Department_Sales	Job_Role_Assistant	Job_Role_Executive	Job_Role_Manager
0	0	0	0	1
1	0	1	0	0
2	0	0	0	1
3	0	0	0	1
4	0	0	0	0

รูปภาพที่ 50 แสดงตัวอย่างผลลัพธ์หลังจาก Encoding (Label + One-hot Encoding)

จากผลการเข้ารหัสตัวแปร (Encoding) ด้วยวิธี Label Encoding และ One-hot Encoding พบว่าข้อมูลหมวดหมู่ได้ถูกแปลงให้อยู่ในรูปแบบที่เหมาะสม เช่น ตัวแปร Attrition ถูกแปลงจากคำว่า “Yes” และ “No” ให้กลายเป็นค่า 1 และ 0 ตามลำดับ ในขณะที่ตัวแปรเชิงหมวดหมู่หลายระดับ เช่น Marital_Status, Department และ Job_Role ถูกแปลงเป็นหลายคอลัมน์ด้วยเทคนิค One-hot Encoding โดยไม่เกิดการซ้ำซ้อน เช่น Department และ Job_Role ก็ถูกแยกเป็นคอลัมน์ย่อย เช่น Department_IT, Department_Marketing, Job_Role_Manager เป็นต้น

3.1.2 Feature Selection Using Correlation + Forest Features Importance

```
# (1) Correlation: เลือก Top 15 ฟีเจอร์ที่สัมพันธ์กับ Attrition
cor_matrix = df_encoded.drop(columns=['Employee_ID']).corr()
corr_top_features = cor_matrix['Attrition'].abs().sort_values(ascending=False).drop('Attrition').head(15)
corr_feature_set = set(corr_top_features.index)

# (2) Random Forest Feature Importance
X_all = df_encoded.drop(columns=['Employee_ID', 'Attrition'])
y_all = df_encoded['Attrition']

rf = RandomForestClassifier(n_estimators=100, random_state=42)
rf.fit(X_all, y_all)

importance_df = pd.DataFrame({
    'Feature': X_all.columns,
    'Importance': rf.feature_importances_
}).sort_values(by='Importance', ascending=False)

rf_top_features = importance_df.head(15)['Feature']
rf_feature_set = set(rf_top_features)

# (3) ฟีเจอร์ที่อยู่ในทั้ง 2 กลุ่ม
selected_features = list(corr_feature_set | rf_feature_set)
print("Features selected from both Correlation & Random Forest:\n", selected_features)

# (4) เตรียมชุดข้อมูลสุดท้าย
df_selected_combined = df_encoded[selected_features + ['Attrition']]
X = df_selected_combined.drop('Attrition', axis=1)
y = df_selected_combined['Attrition']
```

รูปภาพที่ 51 แสดงโค้ด Feature Selection Using Correlation + Forest Features Importance


จากภาพที่ 50 โค้ดชุดนี้ทำหน้าที่ในการเลือกตัวแปร โดยได้ใช้แนวทาง Feature Selection แบบผสม (Hybrid Feature Selection) ซึ่งรวมสองวิธีหลัก ได้แก่ การวิเคราะห์ความสัมพันธ์ด้วย Pearson Correlation และ การประเมินความสำคัญของตัวแปรด้วย Random Forest เพื่อลดจำนวนฟีเจอร์ที่ไม่จำเป็น และคงไว้เฉพาะฟีเจอร์ที่มีศักยภาพในการพยากรณ์สูงสุด

ในขั้นตอนแรก ใช้ Correlation Matrix เพื่อตรวจสอบความสัมพันธ์เชิงเส้นระหว่างแต่ละฟีเจอร์กับตัวแปรเป้าหมาย (Attrition) โดยเลือก 15 ตัวแปรที่มีค่าสัมประสิทธิ์สหสัมพันธ์สูงสุด ซึ่งสะท้อนถึงตัวแปรที่มีแนวโน้มสัมพันธ์อย่างมีนัยกับการลาออก ไม่ว่าจะเป็นทิศทางบวกหรือลบ เช่น รายได้ ระยะเวลาทำงาน หรือการมีปฏิสัมพันธ์กับผู้จัดการ

จากนั้นใช้ Random Forest Classifier ซึ่งเป็นโมเดลเชิง ensemble ที่สามารถจัดอันดับฟีเจอร์ตามความสำคัญในการแยกคลาส โดยการดูว่าแต่ละตัวแปรมีบทบาทในการลดความไม่แน่นอน (impurity) ในการตัดสินใจของต้นไม้มากน้อยเพียงใด และคัดเลือกฟีเจอร์อันดับต้นๆ จำนวน 15 ตัวเช่นกัน

สุดท้ายจึงนำผลจากทั้งสองวิธีมารวมกัน โดยใช้ การรวมแบบ union (ฟีเจอร์ที่อยู่ในอย่างน้อยหนึ่งในสองวิธี) ได้จำนวนตัวแปรที่ผ่านการคัดเลือกทั้งหมด 25 ตัว และนำมาใช้สร้างชุดข้อมูลใหม่ (X, y) สำหรับใช้ในการสร้างโมเดลในขั้นตอนต่อไป

วิธีนี้มีข้อดีตรงที่ช่วย ลดจำนวนตัวแปรโดยไม่สูญเสียข้อมูลสำคัญ และผสมผสานข้อดีของทั้งวิธีสถิติเชิงเส้น (Correlation) และ Machine Learning เชิง ensemble (Random Forest) เพื่อให้ผลลัพธ์มีความแม่นยำและเสถียรยิ่งขึ้นในขั้นตอนการพยากรณ์



รูปภาพที่ 52 กราฟแสดงตัวอย่างผลลัพธ์ Correlation + Forest Features Importance

จากการวิเคราะห์ภาพที่ 52 แสดงการเปรียบเทียบ Top 15 Features ที่ได้จากการเลือกตัวแปรโดยใช้สองวิธีหลัก คือ Correlation Analysis (แถบสีน้ำเงิน) และ Random Forest Feature Importance (แถบสีเหลือง) โดยแสดงค่าคะแนนของแต่ละตัวแปรในแง่ของ ระดับความสัมพันธ์ หรือ ความสำคัญเชิงโมเดลตามลำดับ

จากกราฟจะเห็นว่าบางตัวแปรมีความโดดเด่นเฉพาะในมุมมองของ Random Forest เช่น Monthly_Income, Distance_From_Home, Average_Hours_Worked_Per_Week, Absenteeism และ Years_at_Company ซึ่งมีค่าความสำคัญสูงมาก แต่กลับไม่ได้ปรากฏใน Top 15 ของ Correlation นั่นแปลว่า ตัวแปรเหล่านี้ อาจมีความสัมพันธ์เชิงซ้อนหรือไม่เป็นเชิงเส้นกับ Attrition ทำให้การวัดแบบ Pearson ไม่สามารถจับความสัมพันธ์เหล่านั้นได้ ขณะที่ Random Forest ซึ่งมีความสามารถจัดการกับข้อมูลที่มีความสัมพันธ์ไม่เชิงเส้นกลับประเมินว่ามีความสำคัญสูง

ในทางกลับกัน ตัวแปรอย่าง Job_Role_Manager หรือ Job_Involvement ปรากฏในฝั่ง Correlation แต่ไม่ปรากฏใน Random Forest ซึ่งอาจเป็นเพราะว่า แม้มีความสัมพันธ์เชิงเส้น แต่ไม่ได้ช่วยปรับปรุงการตัดสินใจในโครงสร้างของ Random Forest ได้อย่างชัดเจน หรือมีลักษณะที่ซ้ำซ้อนกับตัวแปรอื่น

ดังนั้น การใช้ทั้งสองวิธีร่วมกันจึงช่วยให้ได้ ชุดตัวแปรที่ครอบคลุมทั้งความสัมพันธ์แบบตรงและซับซ้อน ช่วยเพิ่มประสิทธิภาพของโมเดลโดยไม่พลาดปัจจัยสำคัญที่อาจถูกละเลยถ้าใช้วิธีใดวิธีหนึ่งเพียงอย่างเดียว ถือเป็นกลยุทธ์ที่มีประสิทธิภาพในการคัดเลือกฟีเจอร์สำหรับงานพยากรณ์แบบจำแนก (classification)

3.2 การสร้างชุดข้อมูล (Data Construction)

3.2.1 Oversampling (SMOTE)

ในกรณีนี้ ตัวแปรเป้าหมาย Attrition จากการการสำรวจข้อมูลสถิติเชิงพรรณนา (Summary Statistics) ในหัวข้อ 2.2.2 ซึ่งแสดงว่าพนักงาน “ลาออก” หรือ “ไม่ลาออก” มีการกระจายไม่สมดุลกันอย่างชัดเจน โดยพบว่า

- พนักงาน ลาออก จำนวน 1,997 คน หรือคิดเป็น 19.97%
- ขณะที่พนักงานที่ ยังอยู่กับองค์กร มีจำนวนถึง 8,003 คน หรือคิดเป็น 80.03%

เพื่อแก้ไขปัญหานี้ จึงมีการใช้เทคนิค SMOTE ซึ่งเป็นวิธีการเพิ่มจำนวนตัวอย่างในคลาสที่มีจำนวนน้อย โดยการสร้างตัวอย่างใหม่จากข้อมูลจริงในคลาสเดิม ทำให้ข้อมูลของทั้งสองคลาสมีความสมดุลมากขึ้น

```
smote = SMOTE(random_state=42)
X_selected_resampled, y_selected_resampled = smote.fit_resample(X, y)

# ก่อนทำ SMOTE
original_counts = Counter(y)


# หลังทำ SMOTE
resampled_counts = Counter(y_selected_resampled)

# สร้าง DataFrame เพื่อเปรียบเทียบ
df_compare = pd.DataFrame({
    'Original': pd.Series(original_counts),
    'Resampled': pd.Series(resampled_counts)
})
print(df_compare)
```

รูปภาพที่ 53 แสดงโค้ด Oversampling (SMOTE)

จำนวนตัวอย่างก่อนและหลัง Oversampling:

	Before	After
No Attrition	8003	8003
Yes Attrition	1997	8003



รูปภาพที่ 54,55แสดงผลลัพธ์หลังจากทำ Oversampling (SMOTE)


หลังจากดำเนินการทำ Oversampling ด้วยเทคนิค SMOTE แล้ว พบว่าในชุดข้อมูลใหม่ จำนวนตัวอย่างของพนักงานที่ลาออก (Yes Attrition) เพิ่มขึ้นจากเดิม 1,997 ราย เป็น 8,003 ราย เพื่อให้มีจำนวนเท่ากับพนักงานที่ยังคงอยู่ (No Attrition) ซึ่งเดิมมีอยู่ 8,003 รายเช่นกัน

3.2.2 Standardization

การนำข้อมูล `X_selected_resampled` มาทำการ Standardization ด้วย `StandardScaler` เป็นขั้นตอนสำคัญในการเตรียมข้อมูลก่อนเข้าสู่กระบวนการเรียนรู้ของโมเดล โดย `StandardScaler` จะทำการปรับค่าของแต่ละฟีเจอร์ให้มี ค่าเฉลี่ย (mean) เท่ากับ 0 และ ส่วนเบี่ยงเบนมาตรฐาน (standard deviation) เท่ากับ 1 ซึ่งส่งผลให้ฟีเจอร์ทั้งหมดอยู่ในสเกลเดียวกัน

```
scaler = StandardScaler()
X_selected_resampled_scaled = scaler.fit_transform(X_selected_resampled)
```

รูปภาพที่ 56 แสดงโค้ด Standardization



รูปภาพที่ 57,58กราฟแสดงการเปรียบเทียบค่าเฉลี่ย (mean) และส่วนเบี่ยงเบนมาตรฐาน (standard deviation) ของตัวอย่างฟีเจอร์ก่อนและหลังการทำสเกล

จากรูปภาพที่ 57 - 58 นั้นสามารถสรุปได้ว่าการสเกลข้อมูลช่วยให้แต่ละฟีเจอร์มีค่ากลางและการกระจายที่ใกล้เคียงกันมากขึ้น ซึ่งเป็นประโยชน์อย่างยิ่งสำหรับโมเดลที่อ่อนไหวต่อขนาดของข้อมูล เช่น Logistic Regression และ Neural Network

ในรูปภาพที่ 57 ที่แสดงค่าเฉลี่ย พบว่าค่าเฉลี่ยของฟีเจอร์ทั้งหมดถูกทำให้ใกล้เคียงกับศูนย์หลังการสเกล (ใช้ StandardScaler) ซึ่งเป็นผลลัพธ์ที่คาดหวังจากการ normalize ข้อมูล โดยก่อนสเกลบางฟีเจอร์ เช่น Absenteeism และ Years_in_Current_Role มีค่าเฉลี่ยสูงกว่าฟีเจอร์อื่นมาก ซึ่งอาจทำให้โมเดลให้ความสำคัญกับฟีเจอร์เหล่านี้มากเกินไป

ส่วนรูปภาพที่ 58 ที่แสดงส่วนเบี่ยงเบนมาตรฐาน พบว่าค่าการกระจายของฟีเจอร์ทั้งหมดหลังการสเกลถูกลดให้เหลือประมาณ 1 เท่ากันหมด ขณะที่ก่อนสเกล ฟีเจอร์เช่น Absenteeism และ Years_in_Current_Role มีค่าการกระจายสูง ซึ่งอาจส่งผลให้โมเดลเข้าใจข้อมูลผิดพลาดหรือเกิด bias ในการเรียนรู้

บทที่ 4

การสร้างแบบจำลองข้อมูล (Data Modeling)

4.1 การเลือกใช้เทคนิคแบบจำลอง (Select Modelling Technique)

ในการวิเคราะห์และพยากรณ์อัตราการลาออกของพนักงานในโครงการนี้ ได้มีการเลือกใช้เทคนิคทางเหมืองข้อมูลที่หลากหลาย โดยตั้งใจให้แต่ละเทคนิคทำหน้าที่ตอบคำถามที่แตกต่างกัน เพื่อให้เกิดมุมมองที่ครอบคลุมทั้งในเชิงพยากรณ์ (Predictive), เชิงกลุ่ม (Segmentation) และเชิงสัมพันธ์ (Association)

4.1.1 เทคนิค Logistic Regression

Logistic Regression เป็นเทคนิคพื้นฐานที่ใช้สำหรับการจำแนกข้อมูลแบบสองกลุ่ม (Binary Classification) ซึ่งเหมาะกับกรณีศึกษาในครั้งนี้ที่ต้องการจำแนกว่าพนักงานจะ “ลาออก” หรือ “ไม่ลาออก” โดยเป็นโมเดลที่สามารถตีความผลได้ง่าย และสามารถวิเคราะห์ความสัมพันธ์ระหว่างตัวแปรต้นกับเป้าหมายได้โดยตรง

4.1.2 เทคนิค Random Forest

Random Forest เป็นเทคนิคแบบ Ensemble Learning ที่ทำงานโดยการสร้าง Decision Trees หลายต้น และรวมผลการทำนายเข้าด้วยกันเพื่อเพิ่มความแม่นยำและลดปัญหา Overfitting การทำงานของโมเดลนี้มีประสิทธิภาพสูงในการจัดการกับข้อมูลขนาดใหญ่และสามารถจัดอันดับความสำคัญของตัวแปรได้อีกด้วย

4.1.3 เทคนิค Neural Network

Neural Network เป็นเทคนิคที่มีพื้นฐานมาจากสมการเชิงเส้นของ Linear Regression แต่สามารถจับความสัมพันธ์ที่ซับซ้อนมากขึ้นในข้อมูล โดยเฉพาะกับชุดข้อมูลที่เป็นตัวเลขหลายมิติ เช่น ข้อมูลด้านรายได้ ชั่วโมงทำงาน หรือความพึงพอใจในงาน จึงเหมาะสำหรับใช้ในโครงการนี้เพื่อพยากรณ์แนวโน้มการลาออกที่อาจมีปัจจัยแฝงอยู่

4.1.4 เทคนิค K-Means Clustering

K-Means เป็นเทคนิคแบบ Unsupervised Learning ที่ใช้ในการจัดกลุ่มพนักงานตามลักษณะหรือพฤติกรรมที่คล้ายกัน โดยไม่ต้องอิงตัวแปรเป้าหมาย การแบ่งกลุ่มนี้จะช่วยให้องค์กรสามารถออกแบบนโยบายหรือสวัสดิการที่เหมาะสมกับกลุ่มเป้าหมายแต่ละกลุ่มได้อย่างมีประสิทธิภาพ และยังสามารถใช้ประกอบการวางแผนเชิงกลยุทธ์ร่วมกับผลจากโมเดลจำแนกได้อีกด้วย

4.1.5 เทคนิค Association Rule

Association Rule เป็นเทคนิคที่ใช้ค้นหาความสัมพันธ์ของตัวแปรในข้อมูล เช่น กฎประเภท “ถ้า-แล้ว” เช่น ถ้าพนักงานมีความพึงพอใจต่ำและทำงานล่วงเวลา → มีแนวโน้มลาออก เทคนิคนี้ช่วยให้สามารถระบุ pattern หรือปัจจัยร่วมที่อาจเป็นต้นเหตุของการลาออก ซึ่งเป็นประโยชน์ต่อการกำหนดมาตรการเชิงกลยุทธ์ในองค์กร

4.2 ตัวแบบเหมืองข้อมูล (Data Mining Model)


4.2.1 Logistic Regression

Logistic Regression	
solver	AUTO
☒ reproducible	
maximum number of threads	1000
☒ use regularization	
lambda	0.001
☐ lambda search	
☒ early stopping	
stopping rounds	100
stopping tolerance	0.001
alpha	

รูปภาพที่ 59 แสดงข้อมูลการปรับแต่ง Parameters ของ Logistic Regression

ในการตั้งค่าโมเดล Logistic Regression ได้กำหนดพารามิเตอร์ต่าง ๆ เพื่อให้สอดคล้องกับลักษณะของข้อมูลและแนวทางป้องกันการ overfitting โดยตั้งค่า solver เป็น Auto เพื่อให้ระบบเลือกวิธีการแก้สมการที่เหมาะสมที่สุดกับข้อมูลโดยอัตโนมัติ พร้อมเปิดใช้งาน reproducible เพื่อให้สามารถได้ผลลัพธ์ที่ทำซ้ำได้ (random seed คงที่) ซึ่งเป็นประโยชน์ต่อการทดสอบและเปรียบเทียบ

ในส่วนของการป้องกันการเรียนรู้มากเกินไป ได้เปิดใช้ regularization โดยกำหนดค่า $\lambda = 0.001$ เพื่อควบคุมความแรงของการลงโทษต่อค่าสัมประสิทธิ์ของฟีเจอร์ โดยไม่เปิดใช้ lambda search เพื่อคงค่าคงที่นี้ไว้ในการควบคุมโมเดลตลอดการเรียนรู้ นอกจากนี้ ได้ตั้งค่า early stopping เพื่อหยุดการเรียนรู้หากความแม่นยำไม่ดีขึ้น โดยกำหนด stopping rounds = 100 และ tolerance = 0.001 เพื่อหลีกเลี่ยงการฝึกที่นานโดยไม่จำเป็น



รูปภาพที่ 60 แสดงข้อมูลการปรับแต่ง RapidMiner สำหรับ Logistic Regression ใน Cross-Validation

4.2.2 Random Forest

Random Forest

number of trees ✓ 200 ⓘ

criterion ✓ information gain ⓘ

maximal depth ✓ 20 ⓘ

☒ apply pruning ✓ ⓘ

confidence 0.2 ⓘ

☐ apply prepruning ✓ ⓘ

☒ guess subset ratio ⓘ


voting strategy confidence vote ⓘ

รูปภาพที่ 61 แสดงข้อมูลการปรับแต่ง Parameters ของ Random Forest

ในการตั้งค่าโมเดล Random Forest ได้กำหนดจำนวนต้นไม้ในป่าเป็น 200 ต้น ซึ่งช่วยเพิ่มความเสถียรของโมเดลและลดความผันผวนของผลลัพธ์ โดยใช้เกณฑ์ในการแบ่งข้อมูลเป็น information gain เพื่อเลือกการแยกที่ให้ข้อมูลมากที่สุดในแต่ละ node ซึ่งเหมาะสำหรับการจัดการกับข้อมูลที่มีความหลากหลาย

นอกจากนี้ ได้จำกัดความลึกของต้นไม้ด้วยการตั้งค่า maximal depth = 20 เพื่อป้องกันไม่ให้ต้นไม้เติบโตลึกเกินไปจนเกิด overfitting พร้อมเปิดใช้งาน pruning โดยใช้ confidence = 0.2 เพื่อทำการตัดแต่งกิ่ง (ลดความซับซ้อนของต้นไม้) ด้วยระดับความมั่นใจที่ไม่เข้มงวดมาก ช่วยให้อย่างคงเก็บ pattern สำคัญไว้ได้ ในขณะที่ลดความซับซ้อนที่ไม่จำเป็น

ขณะเดียวกัน prepruning ถูกปิดใช้งานเพื่อให้ต้นไม้สามารถเติบโตได้อย่างเต็มที่ก่อนจะทำ pruning ภายหลัง และเปิดใช้งานการสุ่ม feature subset ในแต่ละ split ซึ่งเป็นหัวใจสำคัญของ Random Forest ที่ช่วยลดความสัมพันธ์ระหว่างต้นไม้แต่ละต้น สุดท้าย เลือกใช้ confidence vote เป็นกลยุทธ์การลงคะแนน เพื่อให้การตัดสินใจรวมของป่ามีความแม่นยำมากขึ้นโดยอิงจากความเชื่อมั่นของแต่ละต้นไม้



รูปภาพที่ 62 แสดงข้อมูลการปรับแต่ง RapidMiner สำหรับ Random Forest ใน Cross-Validation

4.2.3 Neural Network




รูปภาพที่ 63 แสดงข้อมูลการปรับแต่ง Parameters ของ Neural Network

ในการตั้งค่าโมเดล Deep Learning ได้เลือกใช้ฟังก์ชันกระตุ้นแบบ Rectifier (ReLU) ซึ่งเป็นฟังก์ชันที่ได้รับความนิยมในการเรียนรู้เชิงลึก เพราะสามารถช่วยแก้ปัญหา vanishing gradient และเร่งความเร็วในการฝึกโมเดลได้อย่างมีประสิทธิภาพ


โครงสร้างของโครงข่ายถูกกำหนดให้มี 3 ชั้นซ่อน (Hidden Layers) โดยแต่ละชั้นมีจำนวนโหนดเป็น 128, 64 และ 32 ตามลำดับ (hidden layer sizes = (128, 64, 32)), ซึ่งถูกออกแบบให้ลดจำนวนโหนดลงเรื่อย ๆ เพื่อให้โมเดลเรียนรู้พีเจอร์ที่ซับซ้อนจากมากไปหาน้อย (hierarchical representation)

การฝึกโมเดลถูกกำหนดไว้ที่ 10 รอบการเรียนรู้ (epochs = 10) เพื่อให้โมเดลเรียนรู้ข้อมูลในระดับที่เพียงพอโดยไม่ใช้เวลามากเกินไป พร้อมทั้งเปิดใช้งานการคำนวณ variable importances เพื่อให้สามารถวิเคราะห์ความสำคัญของแต่ละพีเจอร์ได้ภายหลัง ซึ่งช่วยในการทำความเข้าใจการทำงานของโมเดลเชิงลึกได้ดีขึ้น อีกทั้งเปิดโหมด reproducible เพื่อให้สามารถทำซ้ำผลลัพธ์ได้อย่างเสถียรในแต่ละครั้งที่รันโมเดล



รูปภาพที่ 64 แสดงข้อมูลการปรับแต่ง RapidMiner สำหรับ Neural Network ใน Cross-Validation

4.2.4 K-Means




รูปภาพที่ 65 แสดงข้อมูลการปรับแต่ง Parameters ของ Loop Parameter

ในการวิเคราะห์เพื่อหาค่า K ที่เหมาะสมสำหรับการทำ K-Means Clustering ได้ใช้เครื่องมือ Loop Parameters กำหนดพารามิเตอร์ Clustering.k ให้ทำการวนค่าตั้งแต่ 2 ถึง 10 โดยมีจำนวนขั้น (Steps) เท่ากับ 10 และสเกลเป็นแบบ linear ซึ่งหมายถึงการทดสอบค่า K ที่ละค่าแบบคงที่ในช่วงที่กำหนด (เช่น K = 2, 3, ..., 10)

เพื่อประเมินว่า K ไດเหมาะสมที่สุด จึงใช้ค่า Davies-Bouldin Index และ Average Within-Cluster Distance (avg_within_distance) เป็นเกณฑ์การเลือกดังนี้

- Davies-Bouldin Index เป็นค่าที่บ่งบอกถึงความกระชับภายในกลุ่มและความแยกกันระหว่างกลุ่ม ยิ่งค่านี้น้อยเท่าใด ยิ่งแสดงว่ากลุ่มมีความแตกต่างกันชัดเจนและกลุ่มภายในมีความคล้ายคลึงกันมาก
- avg_within_distance เป็นค่าเฉลี่ยของระยะห่างระหว่างจุดข้อมูลกับเซนทรอยด์ของคลัสเตอร์ตัวเอง ซึ่งหากค่านี้น้อยยิ่งดี ยิ่งแสดงว่าจุดต่าง ๆ อยู่ใกล้ศูนย์กลางของกลุ่ม และเป็นผลลัพธ์ที่ดีสำหรับการจัดกลุ่ม



รูปภาพที่ 66 แสดงข้อมูลการปรับแต่ง RapidMiner สำหรับ Neural Network ใน Loop Parameter

column name	value
DaviesBouldin	Performance ▾ value ▾ DaviesBouldin ▾
avg_within_distance	Performance ▾ value ▾ avg_within_dist... ▾
k	Clustering ▾ parameter ▾ k ▾

รูปภาพที่ 67 แสดงข้อมูลการปรับแต่ง Parameters ของ Log

4.2.5 Association Rule

ในการวิเคราะห์ด้วยเทคนิค Association Rule Mining จำเป็นต้องแปลงข้อมูลเชิงตัวเลขต่อเนื่อง (continuous numerical features) ให้อยู่ในรูปแบบของช่วง (binning) หรือกลุ่ม (categories) ที่สามารถนำไปใช้กับอัลกอริทึมอย่าง Apriori หรือ FP-Growth ได้ ซึ่งต้องใช้ข้อมูลในรูปแบบรายการ (transactions) ที่ประกอบด้วยค่าประเภทเชิงกลุ่มหรือชื่อ (nominal labels) เท่านั้น ดังนั้น ในขั้นตอนนี้จึงได้ดำเนินการ แปลงข้อมูลตัวแปรเชิงตัวเลขทั้งหมดที่สำคัญให้อยู่ในรูปแบบ binning โดยกำหนดชื่อ label ที่ชัดเจนดังนี้

```
# #SalaryComputation
df_binned = X_selected_resampled.copy()

# Age
df_binned['Age_Bin'] = pd.cut(X_selected_resampled['Age'],
                               bins=[17, 25, 35, 45, 60],
                               labels=['Age18-25', 'Age26-35', 'Age46-60'])

# Years Since Last Promotion
df_binned['Years Since Last Promotion_Bin'] = pd.cut(X_selected_resampled['Years Since Last Promotion'],
                                                       bins=[-1, 0, 2, 5, 10, 40],
                                                       labels=['Promo=0', 'Promo=1-2', 'Promo=3-5', 'Promo=6-10', 'Promo=10+'])

# Monthly Income
df_binned['Monthly Income_Bin'] = pd.cut(X_selected_resampled['Monthly Income'],
                                           bins=[0, 30000, 60000, 100000, float('inf')],
                                           labels=['Income<=30k', 'Income=30k-60k', 'Income=60k-100k', 'Income=100k+'])

# Training hours Last Year
df_binned['Training hours Last Year_Bin'] = pd.cut(X_selected_resampled['Training hours Last Year'],
                                                    bins=[-1, 10, 30, 60, float('inf')],
                                                    labels=['Train=0-10', 'Train=11-30', 'Train=31-60', 'Train=60+'])

# Distance from Home
df_binned['Distance from Home_Bin'] = pd.cut(X_selected_resampled['Distance from Home'],
                                                bins=[-1, 5, 10, 20, float('inf')],
                                                labels=['Dist=0-5km', 'Dist=6-10km', 'Dist=11-20km', 'Dist=20km+'])

# Years at Company
df_binned['Years at Company_Bin'] = pd.cut(X_selected_resampled['Years at Company'],
                                             bins=[-1, 1, 5, 10, 20, float('inf')],
                                             labels=['YearsAtComp=0-1', 'YearsAtComp=2-5', 'YearsAtComp=6-10', 'YearsAtComp=11-20', 'YearsAtComp=20+'])

# Years in Current Role
df_binned['Years in Current Role_Bin'] = pd.cut(X_selected_resampled['Years in Current Role'],
                                                  bins=[-1, 1, 3, 6, 10, float('inf')],
                                                  labels=['CurRole=0-1', 'CurRole=2-3', 'CurRole=4-6', 'CurRole=7-10', 'CurRole=10+'])

# Project Count
df_binned['Project_Count_Bin'] = pd.cut(X_selected_resampled['Project_Count'],
                                         bins=[-1, 2, 4, 6, float('inf')],
                                         labels=['Projects<=2', 'Projects=3-4', 'Projects=5-6', 'Projects=7+'])

# Absenteeism
df_binned['Absenteeism_Bin'] = pd.cut(X_selected_resampled['Absenteeism'],
                                       bins=[-1, 2, 5, 10, float('inf')],
                                       labels=['Abs=0-2', 'Abs=3-5', 'Abs=6-10', 'Abs=11+'])

# Average hours worked
df_binned['Average hours worked_Per Week_Bin'] = pd.cut(X_selected_resampled['Average hours worked_Per Week'],
                                                         bins=[0, 30, 45, 60, float('inf')],
                                                         labels=['Hrs<=30', 'Hrs=31-45', 'Hrs=46-60', 'Hrs=60+'])

# Hourly Rate
df_binned['Hourly_Rate_Bin'] = pd.cut(X_selected_resampled['Hourly_Rate'],
                                       bins=[0, 40, 60, 80, 100],
                                       labels=['Rate<=40', 'Rate=41-60', 'Rate=61-80', 'Rate=81-100'])

# Work Life Balance
df_binned['Work Life Balance_Bin'] = pd.cut(X_selected_resampled['Work Life Balance'],
                                              bins=[0, 1, 2, 3, 4],
                                              labels=['MLB=Poor', 'MLB=fair', 'MLB=Good', 'MLB=Excellent'])

# Relationship with Manager
df_binned['Relationship with Manager_Bin'] = pd.cut(X_selected_resampled['Relationship with Manager'],
                                                      bins=[0, 2, 3, 4, 5],
                                                      labels=['MgrRel=Poor', 'MgrRel=Average', 'MgrRel=Good', 'MgrRel=Excellent'])

# Job Involvement
df_binned['Job_Involvement_Bin'] = pd.cut(X_selected_resampled['Job_Involvement'],
                                           bins=[0, 2, 3, 4, 5],
                                           labels=['Inv=Low', 'Inv=Medium', 'Inv=High', 'Inv=Very High'])
```

```
# Job Satisfaction
df_binned['Job_Satisfaction_Bin'] = pd.cut(X_selected_resampled['Job_Satisfaction'],
                                             bins=[0, 1, 2, 3, 4, 5],
                                             labels=['JSat=Very Low', 'JSat=Low', 'JSat=Moderate', 'JSat=High', 'JSat=Very High'])

# Performance Rating
df_binned['Performance_Rating_Bin'] = pd.cut(X_selected_resampled['Performance_Rating'],
                                                bins=[0, 2, 3, 4, 5],
                                                labels=['Perf=Below Avg', 'Perf=Average', 'Perf=Good', 'Perf=Excellent'])

# Work Environment Satisfaction
df_binned['Work_Environment_Satisfaction_Bin'] = pd.cut(X_selected_resampled['Work_Environment_Satisfaction'],
                                                         bins=[0, 1, 2, 3, 4],
                                                         labels=['EnvSat=Low', 'EnvSat=Moderate', 'EnvSat=High', 'EnvSat=Very High'])

# Job Level
df_binned['Job_Level_Bin'] = pd.cut(X_selected_resampled['Job_Level'],
                                     bins=[0, 1, 2, 3, 4, 5],
                                     labels=['JobLevel=1', 'JobLevel=2', 'JobLevel=3', 'JobLevel=4', 'JobLevel=5'])

# Number of Companies Worked
df_binned['Number_of_Companies_Worked_Bin'] = pd.cut(X_selected_resampled['Number_of_Companies_Worked'],
                                                       bins=[-1, 0, 2, 5, float('inf')],
                                                       labels=['Companies=0', 'Companies=1-2', 'Companies=3-5', 'Companies=6+'])
```

```
# Gender (0 or 1) → ทำให้เป็นหมวดหมู่
df_binned['Gender_Bin'] = X_selected_resampled['Gender'].map({0: 'Female', 1: 'Male'})

# Job_Role_Manager → ให้ label ตรง ๆ
df_binned['Job_Role_Manager_Bin'] = X_selected_resampled['Job_Role_Manager'].map({0: 'Not Manager', 1: 'Manager'})
df_binned['Job_Role_Assistant_Bin'] = X_selected_resampled['Job_Role_Assistant'].map({0: 'Not Assistant', 1: 'Assistant'})

# Department_HR, Department_Marketing
df_binned['Department_HR_Bin'] = X_selected_resampled['Department_HR'].map({0: 'Not HR', 1: 'HR'})
df_binned['Department_Marketing_Bin'] = X_selected_resampled['Department_Marketing'].map({0: 'Not Marketing', 1: 'Marketing'})

# Marital_Status_Married
df_binned['Marital_Status_Married_Bin'] = X_selected_resampled['Marital_Status_Married'].map({0: 'Not Married', 1: 'Married'})

df_binned['Attrition'] = y_selected_resampled.values
df_binned['Attrition'] = df_binned['Attrition'].map({1: 'Attrition_Yes', 0: 'Attrition_No'})
```

รูปภาพที่ 68,69,70,71 การเปลี่ยนข้อมูลคุณลักษณะเป็น categorical

Training_Hours_Last_Year_Bin Distance_From_Home_Bin Years_at_Company_Bin \				Average_Hours_Worked_Per_Week_Bin Hourly_Rate_Bin Work_Life_Balance_Bin \			
0	Train=60+	Dist=20km+	YearsAtComp=20+	0	Hrs=46-60	Rate=81-100	WLB=Poor
1	Train=11-30	Dist=20km+	YearsAtComp=11-20	1	Hrs=46-60	Rate=41-60	WLB=Poor
2	Train=60+	Dist=20km+	YearsAtComp=6-10	2	Hrs=46-60	Rate=61-80	WLB=Excellent
3	Train=0-10	Dist=20km+	YearsAtComp=11-20	3	Hrs=46-60	Rate=<=40	WLB=Poor
4	Train=60+	Dist=20km+	YearsAtComp=2-5	4	Hrs=46-60	Rate=81-100	WLB=Good

Years_in_Current_Role_Bin Project_Count_Bin Absenteeism_Bin \				Relationship_with_Manager_Bin Job_Involvement_Bin Job_Satisfaction_Bin \			
0	CurrRole=10+	Projects=7+	Abs=11+	0	MgrRel=Poor	Inv=Low	JSat=Moderate
1	CurrRole=7-10	Projects=7+	Abs=6-10	1	MgrRel=Poor	Inv=Low	JSat=Low
2	CurrRole=4-6	Projects=3-4	Abs=0-2	2	MgrRel=Good	Inv=Medium	JSat=Very High
3	CurrRole=7-10	Projects=7+	Abs=0-2	3	MgrRel=Good	Inv=Low	JSat=Very Low
4	CurrRole=7-10	Projects=<=2	Abs=11+	4	MgrRel=Poor	Inv=Low	JSat=High

Performance_Rating_Bin Work_Environment_Satisfaction_Bin Job_Level_Bin \				Job_Role_Assistant_Bin Department_HR_Bin Department_Marketing_Bin \			
0	Perf=Below Avg	EnvSat=Very High	JobLevel=5	0	Not Assistant	Not HR	Not Marketing
1	Perf=Below Avg	EnvSat=Very High	JobLevel=4	1	Assistant	HR	Not Marketing
2	Perf=Below Avg	EnvSat=Low	JobLevel=4	2	Not Assistant	Not HR	Marketing
3	Perf=Below Avg	EnvSat=High	JobLevel=4	3	Not Assistant	HR	Not Marketing
4	Perf=Average	EnvSat=Low	JobLevel=1	4	Not Assistant	HR	Not Marketing

Number_of_Companies_Worked_Bin Gender_Bin Job_Role_Manager_Bin \				Marital_Status_Married_Bin	
0	Companies=3-5	Male	Manager	0	Not Married
1	Companies=1-2	Female	Not Manager	1	Not Married
2	Companies=1-2	Female	Manager	2	Married
3	Companies=1-2	Female	Manager	3	Not Married
4	Companies=3-5	Male	Not Manager	4	Married

รูปภาพที่ 72,73,74,75 แสดงชุดข้อมูลหลังจากแปลง Categorical

หลังจากการแปลงค่าข้อมูลเชิงคุณลักษณะ (Categorical Features) ให้อยู่ในรูปแบบช่วงหรือกลุ่ม (Binning) ข้อมูลจะถูกจัดให้อยู่ในหมวดหมู่ที่สื่อความหมายได้ชัดเจน เช่น ช่วงอายุ (Age_Bin), ระยะเวลาที่ไม่ได้รับการเลื่อนตำแหน่ง (Years_Since_Last_Promotion_Bin), รายได้ (Monthly_Income_Bin) และ ชั่วโมงทำงานต่อสัปดาห์ (Average_Hours_Worked_Per_Week_Bin) เป็นต้น

นอกจากนี้ ยังมีการสร้างตัวแปรใหม่จากคุณลักษณะต้นทาง เช่น Job_Role_Manager_Bin หรือ Marital_Status_Married_Bin เพื่อเน้นให้เห็นสถานะของพนักงานแต่ละคนอย่างชัดเจน เช่น เป็นผู้จัดการหรือไม่ แต่งงานแล้วหรือยัง และอยู่ในฝ่ายใด ซึ่งทั้งหมดนี้จะช่วยให้การค้นหารูปแบบหรือพฤติกรรมที่สัมพันธ์กับการลาออกของพนักงานมีความแม่นยำ

```
# ลดจำนวนแถวเหลือ 10,000 หรือ 5,000 ตัวอย่าง
df_sampled = df_binned.sample(n=10000, random_state=42)
print("✅ Sampling done!", df_sampled.shape)

transactions = df_sampled[bin_cols + ['Attrition']].astype(str).values.tolist()

te = TransactionEncoder()
te_array = te.fit(transactions).transform(transactions)
df_te = pd.DataFrame(te_array, columns=te.columns_)

print("Shape of df_te:", df_te.shape)
print("Total unique items:", len(df_te.columns))
print(df_te.dtypes.value_counts()) # ควรมีแค่ bool

# รัน apriori
frequent_items = apriori(df_te, min_support=0.2, use_colnames=True)
# สร้าง rule ทั้งหมด
rules = association_rules(frequent_items, metric='lift', min_threshold=1.0)

# ตรวจสอบกฎเกี่ยวกับ Attrition
rules_target = rules[
    rules['consequents'].astype(str).str.contains('Attrition_Yes')
].sort_values(by='lift', ascending=False)
```

```

# จัดกลุ่มกฎตาม antecedents (แปลงเป็น set เพื่อความเป็น subset)
grouped_rules = []
used_sets = []

for _, row in rules_target.iterrows():
    antecedent_set = set(row['antecedents'])
    is_new = True
    for s in used_sets:
        if antecedent_set <= s or s <= antecedent_set:
            is_new = False
            break
    if is_new:
        grouped_rules.append(row)
        used_sets.append(antecedent_set)

# สร้าง DataFrame ใหม่เฉพาะกฎที่ไม่ซ้ำซ้อน
rules_dedup = pd.DataFrame(grouped_rules)

# คัดเฉพาะกฎที่ confidence >= 0.70 และ lift >= 1.4
highlighted_rules = rules_dedup[(rules_dedup['confidence'] >= 0.73) & (rules_dedup['lift'] >= 1.5)]

# จัดเรียงลำดับจาก confidence มากไปน้อย
highlighted_rules = highlighted_rules.sort_values(by='confidence', ascending=False).reset_index(drop=True)

# แสดงผล
print(highlighted_rules[['antecedents', 'consequents', 'support', 'confidence', 'lift']])

```

รูปภาพที่ 76,77 แสดงโค้ด Association Rule

หลังจากเปลี่ยนข้อมูลคุณลักษณะเป็น categorical แล้วต่อไปก็เป็นกระบวนการค้นหากฎความสัมพันธ์ (Association Rules) โดยใช้เทคนิค Apriori เพื่อวิเคราะห์ลักษณะของพนักงานที่มีแนวโน้มจะลาออกจากองค์กร (Attrition = Yes) จากข้อมูลพนักงานที่ถูกจัดกลุ่ม (binned) แล้วอย่างเหมาะสม โดยเริ่มจากการสุ่มข้อมูลจำนวน 10,000 แถวจากชุดข้อมูลทั้งหมด เพื่อให้การคำนวณมีประสิทธิภาพและใช้เวลาน้อยลง จากนั้นทำการแปลงข้อมูลให้อยู่ในรูปแบบรายการของรายการ (transaction list) และใช้ TransactionEncoder แปลงเป็น DataFrame แบบ one-hot encoding เพื่อใช้ในขั้นตอนการวิเคราะห์ด้วย Apriori algorithm

ในขั้นตอนการขุดกฎความสัมพันธ์ จะใช้ค่า support ขั้นต่ำ 0.2 เพื่อกรองเฉพาะ itemsets ที่เกิดขึ้นอย่างมีนัยสำคัญ และสร้างกฎความสัมพันธ์จาก itemsets เหล่านั้นโดยใช้ค่า metric คือ lift โดยกำหนดขั้นต่ำที่ 1.0 ซึ่งหมายถึงความสัมพันธ์ระหว่าง antecedent และ consequent ต้องมีความสัมพันธ์ที่ดีกว่าการเกิดขึ้นร่วมกันแบบสุ่ม จากนั้นโฟกัสเฉพาะกฎที่มีผลลัพธ์ (consequent) เป็น Attrition_Yes และจัดลำดับตามค่า lift เพื่อหาเงื่อนไขที่มีผลต่อการลาออกมากที่สุด

เพื่อให้ได้กฎที่ไม่ซ้ำซ้อน (non-redundant rules) โค้ดจะจัดกลุ่มกฎที่ antecedent เป็น subset หรือ supersets ของกันและกัน แล้วเลือกมาเฉพาะกฎที่ไม่ทับซ้อนกัน โดยเลือกเฉพาะกฎที่มีค่า confidence ไม่น้อยกว่า 0.73 และค่า lift ไม่น้อยกว่า 1.5 ซึ่งแสดงให้เห็นว่ากฎเหล่านั้นมีความเชื่อมั่นและนัยสำคัญในเชิงสถิติและเชิงธุรกิจสูง

4.3 การทดสอบและประเมินความแม่นยำของตัวแบบเหมืองข้อมูล (Data Mining Model Testing and Assessment)

หลังจากที่ได้ดำเนินการสร้างตัวแบบเหมืองข้อมูลในขั้นตอนก่อนหน้า ขั้นตอนนี้เป็นการนำโมเดลที่ได้มาทำการทดสอบและประเมินประสิทธิภาพในการทำนายผล โดยใช้ประเมินด้วยเทคนิค Cross-Validation เพื่อให้ได้ค่าประสิทธิภาพของโมเดลที่เชื่อถือได้และไม่เกิดการจำค่า (Overfitting)

กระบวนการนี้จะใช้ตัวชี้วัดด้านประสิทธิภาพต่าง ๆ เช่น Accuracy, Precision, Recall, F1-score และ Confusion Matrix เพื่อวัดความแม่นยำในการทำนายของโมเดลในแต่ละคลาส โดยเฉพาะในปัญหาที่มีความไม่สมดุลของข้อมูล (Class Imbalance) เช่น กรณีการลาออกของพนักงาน (Attrition) ซึ่งมีความสำคัญที่จะต้องดูค่าความแม่นยำเชิงเฉพาะกลุ่ม (Class-wise Performance)

4.3.1 Logistic Regression

accuracy: 72.81% +/- 0.98% (micro average: 72.81%)

	true 0	true 1	class precision
pred. 0	5629	1978	74.00%
pred. 1	2374	6025	71.73%
class recall	70.34%	75.28%	

รูปภาพที่ 78 แสดงข้อมูล Performance ของ Logistic Regression

จากผลการทดสอบโมเดล Logistic Regression พบว่าโมเดลสามารถทำงานได้อย่างน่าพอใจในระดับหนึ่ง โดยมีค่า accuracy เฉลี่ยอยู่ที่ 72.81% พร้อมค่าเบี่ยงเบนมาตรฐาน $\pm 0.98\%$ ซึ่งแสดงให้เห็นว่าโมเดลมีความเสถียรพอสมควรในการทำนายผลกับชุดข้อมูลที่หลากหลาย

เมื่อพิจารณาในเชิงรายละเอียดจาก Confusion Matrix พบว่า โมเดลสามารถทำนายพนักงานที่ไม่ได้ลาออก (class 0) ได้ถูกต้องจำนวน 5,629 คน และทำนายผิดจำนวน 2,374 คน ขณะที่พนักงานที่ลาออก (class 1) ถูกทำนายได้ถูกต้องจำนวน 6,025 คน และผิดจำนวน 1,978 คน ทั้งนี้ ค่าความแม่นยำ (precision) ของ class 0 เท่ากับ 74.00% หมายความว่าในจำนวนพนักงานที่โมเดลทำนายว่า “ไม่ลาออก” มี 74% ที่ทำนายได้ถูกต้อง ส่วนความแม่นยำของ class 1 เท่ากับ 71.73% ซึ่งถือว่าอยู่ในระดับใกล้เคียงกัน

ในด้าน recall ซึ่งบ่งชี้ถึงความสามารถในการจับกลุ่มเป้าหมายได้ครบถ้วน class 0 มี recall เท่ากับ 70.34% ส่วน class 1 มี recall เท่ากับ 75.28% แสดงว่าโมเดลสามารถระบุพนักงานที่ลาออกได้มากกว่าพนักงานที่ไม่ลาออก ซึ่งเป็นจุดแข็งของโมเดลในกรณีที่ธุรกิจให้ความสำคัญกับการตรวจจับกลุ่มเสี่ยงที่จะลาออก

4.3.2 Random Forest

accuracy: 82.51% +/- 0.80% (micro average: 82.51%)

	true 0	true 1	class precision
pred. 0	7131	1928	78.72%
pred. 1	872	6075	87.45%
class recall	89.10%	75.91%	

รูปภาพที่ 79 แสดงข้อมูล Performance ของ Random Forest

จากผลการประเมินโมเดล Random Forest พบว่าโมเดลมีประสิทธิภาพสูงกว่า Logistic Regression อย่างชัดเจน โดยสามารถทำค่า accuracy ได้ถึง 82.51% พร้อมค่าเบี่ยงเบนมาตรฐานเพียง $\pm 0.80\%$ ซึ่งบ่งบอกถึงความเสถียรและความแม่นยำในการจำแนกพนักงานที่ลาออกและไม่ลาออกจากงานได้อย่างดี

จาก Confusion Matrix แสดงให้เห็นว่า โมเดลสามารถทำนายพนักงานที่ไม่ลาออก (class 0) ได้ถูกต้องถึง 7,131 คน และผิดพลาดเพียง 872 คน ส่วนพนักงานที่ลาออก (class 1) ถูกทำนายได้ถูกต้อง 6,075 คน และผิด 1,928 คน ทำให้ค่าความแม่นยำ (precision) ของ class 0 อยู่ที่ 78.72% และ class 1 สูงถึง 87.45%

ในส่วนของ recall ซึ่งแสดงถึงความสามารถในการดึงกลุ่มเป้าหมายออกมาได้ครบถ้วน class 0 มีค่า recall สูงถึง 89.10% หมายความว่าโมเดลสามารถจับกลุ่มพนักงานที่ไม่ลาออกได้เกือบทั้งหมด ขณะที่ class 1 มีค่า recall อยู่ที่ 75.91% ซึ่งแม้จะต่ำกว่าคลาส 0 แต่ก็ยังถือว่าอยู่ในระดับดีมาก

4.3.3 Neural Network

accuracy: 77.31% +/- 1.16% (micro average: 77.31%)

	true 0	true 1	class precision
pred. 0	6167	1796	77.45%
pred. 1	1836	6207	77.17%
class recall	77.06%	77.56%	

รูปภาพที่ 80 แสดงข้อมูล Performance ของ Neural Network

จากผลการประเมินโมเดล Neural Network (Deep Learning) พบว่าโมเดลสามารถทำค่า accuracy ได้ที่ 77.31% โดยมีค่าเบี่ยงเบนมาตรฐานที่ $\pm 1.16\%$ ซึ่งถือว่าอยู่ในระดับที่น่าพอใจและแสดงถึงความเสถียรพอสมควรในการทำนายผล โดยประสิทธิภาพของโมเดลนี้อยู่ในระดับกลางระหว่าง Logistic Regression (72.81%) และ Random Forest (82.51%)

จาก Confusion Matrix โมเดลสามารถทำนายพนักงานที่ไม่ลาออก (class 0) ได้ถูกต้องจำนวน 6,167 คน และผิดพลาด 1,836 คน ขณะที่พนักงานที่ลาออก (class 1) ทำนายได้ถูกต้อง 6,207 คน และผิดพลาด 1,796 คน ส่งผลให้ค่าความแม่นยำ (precision) ของ class 0 อยู่ที่ 77.45% และ class 1 ที่ 77.17%

สำหรับค่า recall หรือความสามารถในการจำแนกตัวอย่างแต่ละคลาสได้ครบถ้วน class 0 มีค่า recall 77.06% ส่วน class 1 มีค่า recall 77.56% ซึ่งค่าทั้งสองใกล้เคียงกันมาก แสดงว่าโมเดลไม่มีความลำเอียงต่อคลาสใดคลาสหนึ่ง และสามารถจำแนกทั้งพนักงานที่ลาออกและไม่ลาออกได้อย่างสมดุล

4.3.4 K-Means

DaviesBouldin	avg_within_distance	k ↑
3.394	23.945	2
3.594	22.924	3
3.625	22.233	4
3.228	21.577	5
3.383	21.103	6
3.270	20.803	7
3.425	20.605	8
3.557	20.409	9
3.633	20.198	10

รูปภาพที่ 81 แสดงข้อมูลผลลัพธ์ของ K-Means

จากผลการประเมินค่าตัวชี้วัดสำหรับการหาค่าจำนวนกลุ่ม (k) ที่เหมาะสมในการทำ K-Means Clustering โดยใช้เกณฑ์ Davies-Bouldin Index และ Average Within-Cluster Distance พบว่าเมื่อค่า k เพิ่มขึ้น ค่าระยะห่างภายในคลัสเตอร์ (avg_within_distance) มีแนวโน้มลดลงอย่างต่อเนื่อง ซึ่งเป็นสิ่งที่คาดหวัง เนื่องจากจำนวนกลุ่มที่มากขึ้นจะทำให้คลัสเตอร์เล็กลงและมีความกระจุกตัวมากขึ้น อย่างไรก็ตาม ค่าของ Davies-Bouldin Index (DBI) ซึ่งควรจะ “ต่ำที่สุด” เพื่อแสดงถึงการแบ่งกลุ่มที่ดี กลับมีค่าต่ำสุดที่ k = 5 โดย DBI = 3.23

แม้ว่า avg_within_distance จะยังคงลดลงต่อไปเมื่อ k เพิ่ม แต่ค่าดังกล่าวลดลงในอัตราที่ช้าลง หลังจาก k = 5 และ DBI กลับแย่ลง ดังนั้นจึงสามารถสรุปได้ว่า จำนวนคลัสเตอร์ที่เหมาะสมที่สุดในบริบทนี้ คือ k = 5 ซึ่งเป็นจุดสมดุลระหว่างการกระจุกตัวของกลุ่ม (low within-cluster distance) และการแยกกลุ่ม (low DBI) โดยไม่ทำให้โมเดลซับซ้อนเกินความจำเป็น

4.3.5 Association Rules

	antecedents			
0	(Not Manager, Not Assistant, Not Marketing, Not HR, Not Married, Female)			
1	(Income=<=30k, MgrRel=Poor, Not Manager, Not Assistant, Not Marketing, Not Married)			
2	(Companies=1-2, Not Manager, Not Marketing, Not Assistant, Not HR)			
3	(MgrRel=Poor, Not Manager, Not Marketing, Not Assistant, Not HR)			
4	(Income=<=30k, Not Manager, Not Assistant, Not Marketing, Not Married, Female)			
	consequents	support	confidence	lift
0	(Attrition_Yes)	0.2124	0.814105	1.654685
1	(Attrition_Yes)	0.2004	0.749719	1.523820
2	(Attrition_Yes)	0.2128	0.739917	1.503895
3	(Attrition_Yes, Income=<=30k)	0.2184	0.738337	1.500684
4	(Not HR, Attrition Yes)	0.2124	0.733679	1.605775

รูปภาพที่ 82 แสดงข้อมูลผลลัพธ์ของ Association Rules

จากการวิเคราะห์กฎความสัมพันธ์เพื่อศึกษาปัจจัยที่เกี่ยวข้องกับการลาออกของพนักงาน พบว่ามีกลุ่มของกฎที่มีความน่าสนใจอย่างยิ่ง โดยเฉพาะกฎที่มีค่า confidence สูงถึง 81.41% และค่า lift เท่ากับ 1.65 ซึ่งสะท้อนถึงความสัมพันธ์ที่แข็งแกร่งระหว่างคุณลักษณะบางประการของพนักงานกับพฤติกรรมการลาออก กล่าวคือ เมื่อพนักงานมีคุณลักษณะตรงกับเงื่อนไขในกลุ่ม antecedents เช่น เป็นเพศหญิง ไม่ได้แต่งงาน ไม่มีตำแหน่งเป็นผู้จัดการ ผู้ช่วย ฝ่ายขาย หรือ HR ก็จะมีแนวโน้มที่จะลาออกสูงมาก โดยมีโอกาสลาออกมากกว่าพนักงานทั่วไปถึง 1.65 เท่า

นอกจากนี้ ยังมีกฎอื่น ๆ ที่มีลักษณะ antecedents ใกล้เคียงกัน เช่น เพิ่มเงื่อนไขว่ามีรายได้ไม่เกิน 30,000 บาท หรือมีความสัมพันธ์กับผู้จัดการในระดับต่ำ ก็ยังคงแสดงให้เห็นค่า confidence อยู่ในระดับสูงระหว่าง 73–75% และค่า lift เกินกว่า 1.5 ซึ่งตอกย้ำถึงความสำคัญของปัจจัยร่วมหลายด้าน เช่น เพศ รายได้ ความสัมพันธ์กับหัวหน้างาน ตำแหน่ง และสถานภาพสมรส ที่ล้วนมีผลต่อความเสี่ยงในการลาออกอย่างชัดเจน ผลลัพธ์เหล่านี้สามารถนำไปประยุกต์ใช้ในการสร้างแบบจำลองการคาดการณ์ และกำหนดแนวทางในการบริหารจัดการทรัพยากรบุคคลเพื่อรักษาพนักงานกลุ่มเสี่ยงได้อย่างมีประสิทธิภาพ

บทที่ 5

สรุปผล อภิปรายผลและข้อเสนอแนะ

(Conclusion, Discussion and Suggestion)

5.1 การสรุปผล (Conclusion)

ในบทนี้จะเป็นการสรุปผลการวิเคราะห์ข้อมูลพนักงานขององค์กรโดยใช้กระบวนการเหมืองข้อมูล (Data Mining) ที่ได้ดำเนินการในบทก่อนหน้านี้ ตั้งแต่ขั้นตอนการเตรียมข้อมูล (Data Preparation), การเลือกตัวแปรที่มีความสำคัญ (Feature Selection), การจัดการความไม่สมดุลของข้อมูล (SMOTE), การสร้างและประเมินประสิทธิภาพของโมเดลการทำนาย (Classification Models) เช่น Logistic Regression, Random Forest และ Deep Learning รวมถึงการจัดกลุ่มพนักงานด้วยวิธีการ Clustering (K-Means) และการค้นหากฎความสัมพันธ์ด้วย Association Rule Mining

ผลการวิเคราะห์ทั้งหมดได้ช่วยให้เห็นภาพรวมของพนักงานที่มีแนวโน้มลาออก (Attrition) จากตัวแปรสำคัญต่าง ๆ เช่น รายได้ อายุ ประสบการณ์ทำงาน ความพึงพอใจในงาน ความสัมพันธ์กับหัวหน้า และชั่วโมงการทำงาน ซึ่งสามารถนำไปใช้ในการวางแผนบริหารทรัพยากรมนุษย์อย่างมีประสิทธิภาพ บทนี้จะนำเสนอข้อค้นพบที่สำคัญ พร้อมทั้งอภิปรายผลในเชิงธุรกิจและเสนอแนะแนวทางที่องค์กรสามารถนำไปปรับใช้ในการรักษาพนักงานกลุ่มเสี่ยงได้อย่างเป็นรูปธรรม

5.1.1 Classification Models

ตารางที่ 3 ผลลัพธ์การทำงานของ Classification Models

Model	Accuracy	Precision (Attrition)	Precision (No Attrition)	Recall (Attrition)	Recall (No Attrition)
Logistic Regression	72.81%	71.73%	74.00%	75.28%	70.34%
Random Forest	82.51%	87.45%	78.72%	75.91%	89.10%
Neural Network	77.31%	77.17%	77.45%	77.56%	77.06%

จากตารางที่ 3 แสดงผลการเปรียบเทียบประสิทธิภาพของโมเดลการจำแนก (Classification Models) ได้แก่ Logistic Regression, Random Forest และ Neural Network ในการทำนายการลาออกของพนักงาน โดยพิจารณาจากค่าความแม่นยำ (Accuracy), ความแม่นยำตรง (Precision) และค่าความครอบคลุม (Recall) ของแต่ละกลุ่ม

ผลการทดสอบแสดงให้เห็นว่า Random Forest ให้ผลลัพธ์ที่ดีที่สุด โดยมีค่า Accuracy สูงถึง 82.51% และมีค่า Recall ในกลุ่มที่ไม่ลาออกถึง 89.10% ซึ่งสะท้อนว่าโมเดลสามารถระบุพนักงานที่ไม่มีแนวโน้มจะลาออกได้อย่างแม่นยำ ในขณะที่ Neural Network ให้ผลค่อนข้างสมดุลระหว่าง Precision และ

Recall ในทั้งสองกลุ่ม ส่วน Logistic Regression แม้จะมี Accuracy ต่ำที่สุดที่ 72.81% แต่ก็ยังแสดงความสามารถในการทำนายกลุ่มที่ลาออกได้พอสมควร กล่าวโดยสรุป โมเดล Random Forest เหมาะสมที่สุดสำหรับกรณีศึกษา นี้ เนื่องจากให้ผลแม่นยำสูงและสามารถประมวลผลข้อมูลที่ซับซ้อนได้ดี

5.1.2 Clustering (K-Means)

จากผลการแบ่งกลุ่มโดยใช้เทคนิค K-Means พบว่าสามารถจัดกลุ่มพนักงานทั้งหมดจำนวน 16,006
ดังนี้

Cluster Model


```
Cluster 0: 7886 items
Cluster 1: 2219 items
Cluster 2: 2136 items
Cluster 3: 1903 items
Cluster 4: 1862 items
Total number of items: 16006
```

รูปภาพที่ 83 แสดงจำนวนพนักงานในแต่ละคลัสเตอร์ของ K-Means

จากรูปภาพที่ 83 สามารถแบ่งพนักงานทั้งหมดเป็น 5 กลุ่มหลัก ได้แก่

- Cluster 0 มีจำนวนมากที่สุดที่ 7,886 คน (ประมาณ 49.3%)
- Cluster 1 จำนวน 2,219 คน (13.9%)
- Cluster 2 จำนวน 2,136 คน (13.3%)
- Cluster 3 จำนวน 1,903 คน (11.9%)
- Cluster 4 จำนวน 1,862 คน (11.6%)


พนักงานแต่ละกลุ่มมีลักษณะเด่นเฉพาะ เช่น ความพึงพอใจในการทำงาน ระดับตำแหน่ง รายได้ ชั่วโมงการทำงาน และความผูกพันต่อองค์กร ซึ่งสามารถนำไปใช้ในการวางแผนเชิงกลยุทธ์ด้านการบริหารทรัพยากรบุคคลได้อย่างมีประสิทธิภาพ โดยเฉพาะการกำหนดนโยบายดูแลหรือพัฒนาพนักงานเฉพาะกลุ่มตามคุณลักษณะที่ปรากฏ



รูปภาพที่ 84 แสดงกราฟเส้นของค่าเฉลี่ยมาตรฐาน (standardized mean) ของแต่ละฟีเจอร์ในแต่ละคลัสเตอร์

จากรูปภาพที่ 84 แสดงลักษณะเฉลี่ยของตัวแปรสำคัญในแต่ละคลัสเตอร์ โดยจำแนกพนักงานทั้งหมดออกเป็น 5 กลุ่มตามคุณลักษณะร่วมที่โดดเด่น จากการวิเคราะห์กลุ่ม (Clustering) พบว่า

- Cluster 0 เป็นกลุ่มใหญ่ที่สุดพนักงานมีลักษณะทั่วไปกระจายหลากหลายแผนก
- Cluster 1 คือกลุ่มพนักงานอาวุโสที่มีประสบการณ์สูง รายได้ดี และมีความผูกพันต่อองค์กรสูง
- Cluster 2 ประกอบด้วยผู้จัดการและฝ่ายทรัพยากรบุคคล มีบทบาทเชิงยุทธศาสตร์
- Cluster 3 คือพนักงานฝ่ายการตลาดและผู้ช่วย โดยเฉพาะเพศหญิงในตำแหน่งระดับต้น มีรายได้น้อย
- Cluster 4 เป็นพนักงานที่ทำงานหนักและชั่วโมงงานสูง



รูปภาพที่ 85 แสดงกราฟจำนวน Attrition ในแต่ละคลัสเตอร์

ในการสรุปผล (Conclusion) ของการวิเคราะห์ด้วยเทคนิค K-Means Clustering สามารถสรุปได้ว่าโมเดลสามารถจำแนกพนักงานออกเป็น 5 กลุ่มหลักที่มีคุณลักษณะเฉพาะแตกต่างกันอย่างชัดเจน ทั้งในด้านพฤติกรรม ทักษะ และสภาพการทำงาน ซึ่งมีความเกี่ยวข้องโดยตรงกับแนวโน้มการลาออก (Attrition) จากรูปภาพที่ 84 แสดงจำนวนพนักงานที่ลาออก (Attrition = 1) และไม่ลาออก (Attrition = 0) ในแต่ละคลัสเตอร์พบว่า

- Cluster 0 มีจำนวนพนักงานลาออกสูงที่สุดถึง 5,528 คนจาก 7,886 คน หรือคิดเป็น มากกว่า 70% ของกลุ่ม แสดงให้เห็นว่าแม้อันดับนี้จะมีจำนวนมากที่สุดและมีความหลากหลายในแง่ตำแหน่งหรือแผนก แต่กลับมีแนวโน้มลาออกสูงที่สุด
- Cluster 1 และ Cluster 2 เป็นกลุ่มที่มีแนวโน้ม “ไม่ลาออก” สูง โดยมีจำนวนพนักงานไม่ลาออก มากกว่าพนักงานที่ลาออกอย่างชัดเจน (เช่น Cluster 1 มี 1,594 คนไม่ลาออก เทียบกับ 625 คนที่ลาออก) สะท้อนให้เห็นถึงเสถียรภาพของกลุ่มพนักงานที่มีประสบการณ์สูง บทบาทสำคัญในองค์กร หรือมีความผูกพันที่แน่นแฟ้น
- Cluster 3 และ Cluster 4 มีสัดส่วนการลาออกค่อนข้างสูงเมื่อเทียบกับขนาดกลุ่ม เช่น Cluster 3 มีอัตราการลาออกประมาณ 38.8% และ Cluster 4 มีอัตราประมาณ 29.4% โดยเฉพาะ Cluster 3 ที่ประกอบด้วยพนักงานฝ่ายการตลาดและผู้ช่วย เพศหญิงเป็นส่วนใหญ่ ซึ่งอาจรู้สึกไม่มีโอกาสเติบโต หรือได้รับการสนับสนุนไม่เพียงพอ ในขณะที่ Cluster 4 เป็นกลุ่มที่มีชั่วโมงทำงานสูงและภาระงานมาก จึงมีความเสี่ยงต่ออาการเหนื่อยล้าหรือ Burnout

5.1.3 Association Rule Mining

จากการวิเคราะห์ข้อมูลด้วยเทคนิค Association Rule Mining พบว่ามีเงื่อนไขที่มีความสัมพันธ์สูงกับการลาออกของพนักงาน โดยการตรวจสอบกฎที่เกี่ยวข้องกับการลาออก (Attrition) ซึ่งมีค่า confidence และ lift สูง โดยกฎที่มีความสัมพันธ์ชัดเจนที่สุด ได้แก่ กฎที่บ่งชี้ถึงลักษณะพนักงานที่มีแนวโน้มลาออกสูง เช่น เพศ รายได้ ตำแหน่ง และความสัมพันธ์กับผู้จัดการ ข้อมูลเหล่านี้สามารถนำไปใช้ในการประเมินและกำหนดกลยุทธ์เพื่อการบริหารจัดการทรัพยากรบุคคลได้อย่างมีประสิทธิภาพ

ในตารางด้านล่างนี้ แสดงกฎความสัมพันธ์ที่สำคัญซึ่งแสดงถึงปัจจัยต่างๆ ที่มีผลต่อการลาออกของพนักงาน และสามารถนำข้อมูลเหล่านี้ไปปรับใช้ในการวางแผนเชิงกลยุทธ์ในอนาคต

ตารางที่ 4 กฎความสัมพันธ์ที่สัมพันธ์กับการลาออกของพนักงาน

ลำดับ	Antecedents (เงื่อนไขก่อนหน้า)	Consequent (ผลลัพธ์)	Support	Confidence	Lift
1	Female, Income $\leq$ 30k, Not Assistant, Not Marketing, Not Married, Not HR, Not Manager	Attrition_Yes	0.2124	0.8141	1.6547
2	MgrRel = Poor, Not Assistant, Not Marketing, Not Married, Not Manager	Attrition_Yes	0.2004	0.7497	1.5238
3	Not Assistant, Not Marketing, Companies = 1-2, Not HR, Not Manager	Income $\leq$ 30k, Attrition_Yes	0.2128	0.7399	1.5039
4	Income $\leq$ 30k, MgrRel = Poor, Not Assistant, Not Marketing, Not HR, Not Manager	Attrition_Yes	0.2184	0.7383	1.5007

จากตารางที่ 4 พบว่าเงื่อนไขหลายประการมีความสัมพันธ์สูงกับการลาออกของพนักงาน โดยกฎที่ 1 มีค่า confidence สูงที่สุดที่ 81.41% และค่า lift เท่ากับ 1.65 แสดงให้เห็นว่าพนักงานที่เป็นเพศหญิง รายได้ไม่เกิน 30,000 บาท ไม่ดำรงตำแหน่งผู้ช่วย ไม่อยู่ในสายงานการตลาด ไม่แต่งงาน ไม่อยู่ในฝ่ายทรัพยากรบุคคล และไม่ดำรงตำแหน่งผู้จัดการ มีแนวโน้มลาออกสูงกว่ากลุ่มอื่นๆ อย่างมีนัยสำคัญ

กฎที่ 2 ยังเน้นถึงประเด็นความสัมพันธ์กับผู้จัดการ โดยระบุว่าพนักงานที่ได้รับการประเมินความสัมพันธ์กับผู้จัดการว่า “แย่ (MgrRel = Poor)” และไม่ได้อยู่ในตำแหน่งหลักหรือสายงานสำคัญต่างๆ ก็มีความเสี่ยงลาออกเช่นกัน โดยมี confidence ถึง 74.97% และ lift 1.52 ซึ่งบ่งชี้ถึงความสัมพันธ์ที่ดีกว่าการเกิดขึ้นร่วมกันโดยบังเอิญ

ในขณะที่กฎที่ 3 และ 4 ตอกย้ำถึงผลกระทบของ ประสบการณ์การทำงานต่ำ (Companies = 1-2), รายได้ต่ำ และ ความสัมพันธ์กับผู้จัดการที่ไม่ดี ซึ่งเป็นปัจจัยเสี่ยงร่วมกันที่มีผลอย่างชัดเจนต่อการลาออก โดยกฎที่ 3 แสดงให้เห็นว่าพนักงานที่ไม่ได้อยู่ในตำแหน่งหลัก และมีประสบการณ์เพียงเล็กน้อย มีโอกาสลาออกสูง (confidence 73.99%, lift 1.50). ส่วนกฎที่ 4 เน้นการรวมกันของรายได้ต่ำและความสัมพันธ์ที่ไม่ดีระหว่างหัวหน้าและลูกน้อง

5.2 การอภิปรายผล (Discussion)

5.2.1 Classification Models

จากผลการเปรียบเทียบประสิทธิภาพของโมเดลจำแนกประเภท (Classification Models) ได้แก่ Logistic Regression, Random Forest และ Neural Network ในการทำนายการลาออกของพนักงาน พบว่าโมเดลแต่ละแบบมีจุดเด่นและข้อจำกัดที่แตกต่างกัน โดยเฉพาะในแง่ของค่าความแม่นยำ (Accuracy), ความแม่นยำตรง (Precision) และค่าความครอบคลุม (Recall) ในกลุ่มที่ลาออก (Attrition) และไม่ลาออก (No Attrition)

Random Forest แสดงประสิทธิภาพโดยรวมดีที่สุด โดยมีค่า Accuracy สูงถึง 82.51% พร้อมค่า Precision ในกลุ่มพนักงานที่ลาออกถึง 87.45% และ Recall ในกลุ่มที่ไม่ลาออกสูงถึง 89.10% ซึ่งแสดงให้เห็นว่าโมเดลนี้สามารถคัดกรองพนักงานที่ไม่มีแนวโน้มลาออกได้แม่นยำ และสามารถระบุพนักงานที่มีแนวโน้มจะลาออกได้ดีพอสมควร ประสิทธิภาพนี้ส่วนหนึ่งมาจากลักษณะของโมเดลที่ใช้การเรียนรู้แบบรวมหลายต้นไม้ตัดสินใจ (Ensemble Learning) ซึ่งช่วยให้ตรวจจับความสัมพันธ์ระหว่างตัวแปรได้ดีแม้ในกรณีที่ข้อมูลมีลักษณะไม่เชิงเส้นหรือซับซ้อน

Neural Network มีความสามารถในการจับรูปแบบที่ซับซ้อนเช่นกัน และแสดงผลลัพธ์ที่สมดุลระหว่างกลุ่มลาออกและไม่ลาออก โดยให้ค่า Precision และ Recall ในระดับใกล้เคียงกันทั้งสองกลุ่ม อย่างไรก็ตาม เนื่องจากเป็นโมเดลที่ต้องการการปรับจูน (Hyperparameter tuning) มากกว่า จึงอาจมีข้อจำกัดในด้านความเสถียรหากไม่ได้ตั้งค่าที่เหมาะสม

Logistic Regression ซึ่งเป็นโมเดลเชิงเส้นที่ตีความง่าย แม้จะมี Accuracy ต่ำที่สุด (72.81%) แต่ก็ให้ค่า Recall ในกลุ่มลาออกถึง 75.28% ทำให้สามารถนำมาใช้ในการวิเคราะห์เชิงนโยบายหรือศึกษาความสัมพันธ์ระหว่างตัวแปรแบบตรงไปตรงมา เช่น เพื่อดูว่าปัจจัยใดส่งผลบวกหรือลบต่อโอกาสลาออกของพนักงาน

นอกเหนือจากประสิทธิภาพเชิงเทคนิคแล้ว การใช้โมเดลเหล่านี้ยังสะท้อนให้เห็น “พฤติกรรมการลาออกของพนักงาน” ผ่านตัวแปรที่สำคัญในกระบวนการเรียนรู้ของโมเดล เช่น Job Satisfaction, Years at Company, Work-Life Balance, และ Job Involvement ซึ่งเป็นปัจจัยที่สอดคล้องกับทฤษฎีด้านการจัดการทรัพยากรมนุษย์อย่างความพึงพอใจ ความสัมพันธ์กับหัวหน้างาน และสมดุลในการใช้ชีวิต ล้วนส่งผลต่อแรงจูงใจและการตัดสินใจอยู่หรือออกจากองค์กร

ดังนั้นประโยชน์ของโมเดลจำแนกเหล่านี้จึงไม่จำกัดเพียงการทำนาย แต่ยังสามารถใช้เป็นเครื่องมือช่วยฝ่าย HR ในการออกแบบนโยบายเชิงรุก เช่น การวางแผนดูแลพนักงานกลุ่มเสี่ยง การจัดโปรแกรมพัฒนาอาชีพเฉพาะกลุ่ม หรือการปรับสิ่งแวดล้อมการทำงานให้เหมาะสมยิ่งขึ้น เพื่อรักษากำลังคนที่มีคุณภาพไว้ในระยะยาว

5.2.2 Clustering (K-Means)

จากการแบ่งกลุ่มพนักงานโดยใช้เทคนิค K-Means ทำให้สามารถจำแนกพนักงานทั้งหมดออกเป็น 5 กลุ่ม ซึ่งแต่ละกลุ่มมีลักษณะเฉพาะที่ต่างกันอย่างชัดเจน ทั้งด้านอายุ รายได้ ประสิทธิภาพการทำงาน ความสัมพันธ์กับหัวหน้า และระดับความผูกพันต่อองค์กร การวิเคราะห์เหล่านี้ให้ข้อมูลเชิงลึกที่สำคัญในการดูแลพนักงานแต่ละกลุ่มได้ตรงจุดมากขึ้น

Cluster 0 เป็นกลุ่มใหญ่ที่สุด มีพนักงานถึง 7,886 คน หรือคิดเป็นเกือบครึ่งขององค์กร และที่น่าสนใจคือในกลุ่มนี้มีพนักงานที่ลาออกถึง 5,528 คน หรือประมาณ 70% ซึ่งถือว่าสูงมาก กลุ่มนี้มักเป็นพนักงานทั่วไป ที่กระจายอยู่ในหลายแผนก แต่มีจุดร่วมคือ ระดับความพึงพอใจในการทำงานและความผูกพันกับองค์กรค่อนข้างต่ำ หลายคนอาจรู้สึกว่าคุณค่าตนไม่มีความสำคัญหรือไม่ได้รับการดูแลที่ดีพอ ซึ่งนำไปสู่การตัดสินใจลาออก องค์กรควรให้ความสำคัญกับกลุ่มนี้เป็นพิเศษ เพราะหากจัดการได้ดี จะลดการลาออกได้มากที่สุดในองค์กร

Cluster 1 มีพนักงาน 2,219 คน โดยมีผู้ที่ลาออกเพียง 625 คน (28%) กลุ่มนี้แสดงให้เห็นถึงพนักงานที่อยู่กับองค์กรมานาน รายได้ดี และมักมีความรับผิดชอบสูง เช่น เป็นหัวหน้างาน หรืออยู่ในตำแหน่งที่สำคัญ มีความภักดีต่อองค์กรในระดับที่น่าพอใจ จุดแข็งของกลุ่มนี้คือ ความมั่นคงและความชำนาญ ดังนั้นองค์กรควรเน้นการวางแผนความก้าวหน้าในสายอาชีพ และให้โอกาสในการพัฒนาทักษะเพิ่มเติม เพื่อรักษากลุ่มนี้ไว้ให้นานที่สุด

Cluster 2 มีจำนวน 2,136 คน และมีอัตราการลาออกที่ต่ำ (564 คน หรือ 26%) ลักษณะเด่นคือมีพนักงานที่มีบทบาทสำคัญในองค์กร เช่น ผู้จัดการ หรือฝ่ายทรัพยากรบุคคล กลุ่มนี้เป็นกำลังหลักในการกำหนดนโยบายหรือวัฒนธรรมองค์กร มีประสบการณ์สูงและได้รับการฝึกอบรมอย่างต่อเนื่อง จึงควรสนับสนุนให้พวกเขาทำหน้าที่เป็น “ผู้ถ่ายทอด” ค่านิยมองค์กรให้กับกลุ่มอื่น

Cluster 3 มี 1,903 คน โดยลาออกถึง 738 คน (ประมาณ 38.8%) กลุ่มนี้ประกอบด้วยพนักงานระดับต้น เช่น ฝ่ายการตลาด หรือตำแหน่งผู้ช่วย มีสัดส่วนเพศหญิงค่อนข้างสูง รายได้ไม่มาก และมีชั่วโมงฝึกอบรมน้อย กลุ่มนี้อาจรู้สึกว่าคุณไม่มีโอกาสเติบโต หรือไม่ได้รับความใส่ใจเท่าที่ควร หากไม่ได้รับการสนับสนุนเพิ่มเติม อาจตัดสินใจลาออกได้ง่าย องค์กรควรพิจารณาให้การดูแลพิเศษกับกลุ่มนี้ เช่น การจัดโปรแกรมพี่เลี้ยง หรือแนวทางพัฒนาอาชีพที่ชัดเจน

Cluster 4 มีพนักงาน 1,862 คน และลาออก 548 คน (29.4%) กลุ่มนี้ทำงานหนักมาก มีชั่วโมงทำงานเฉลี่ยต่อสัปดาห์และจำนวนโครงการที่รับผิดชอบสูงกว่ากลุ่มอื่นๆ บ่งชี้ว่ามีภาระงานมาก ซึ่งแม้ว่าค่าประสิทธิภาพในการทำงานและความพึงพอใจจะอยู่ในระดับปานกลาง แต่มีความเสี่ยงต่อความเครียดและหมดไฟจากการทำงาน องค์กรควรพิจารณาจัดการภาระงานให้เหมาะสม รวมถึงส่งเสริมสมดุลชีวิตและการดูแลสุขภาพจิตให้พนักงานกลุ่มนี้

ตารางที่ 5 ตารางสรุปผลลัพธ์

Cluster	จำนวน	อัตราการลาออก	ลักษณะเด่น	กลยุทธ์แนะนำ
0	7,886	~70%	พนักงานทั่วไป, Engagement ต่ำ	สร้างแรงจูงใจ, วัฒนธรรมองค์กร
1	2,219	~28%	อาวุโส, รายได้สูง, ทำงานนาน	เส้นทางอาชีพ, Coaching
2	2,136	~26%	ผู้จัดการ, HR, Job Level สูง	รักษาคณเฑาะ, เสริมบทบาทผู้นำ
3	1,903	~39%	ผู้ช่วย, การตลาด, หญิง, รายได้น้อย	Mentorship, ส่งเสริมโอกาส
4	1,862	~29%	ชั่วโมงงานสูง, เสี่ยง Burnout	Work-Life Balance, ลดภาระงาน

เมื่อเปรียบเทียบ Cluster 0 และ Cluster 1 จากตารางที่ 5 พบว่าแม้ Cluster 0 จะมีพนักงานมากกว่า Cluster 1 ถึง 3 เท่า แต่กลับมีอัตราการลาออกสูงกว่าหลายเท่า แสดงถึงปัญหาในการดูแลพนักงานระดับล่างที่ขาด engagement ขณะที่ Cluster 1 มีลักษณะของความมั่นคงและผูกพันสูง ซึ่งควรเป็นต้นแบบในการออกแบบนโยบายดูแลพนักงาน และเมื่อเปรียบเทียบ Cluster 2 และ Cluster 3 สะท้อนความต่างระหว่างกลุ่มผู้บริหารและพนักงานตำแหน่งต้น โดยกลุ่มหลังมีอัตราการลาออกสูงกว่า สะท้อนถึงความเปราะบางในกลุ่มแรงงานระดับเริ่มต้นที่ควรให้ความสำคัญไม่แพ้กลุ่มผู้บริหาร

ทำให้เมื่อพิจารณาผลลัพธ์ของโมเดล Classification โดยเฉพาะ Random Forest ที่สามารถทำนายการลาออกได้แม่นยำที่สุดในกลุ่มพนักงานลาออก (Recall = 75.91%) จะพบว่าคลัสเตอร์ที่มีอัตราการลาออกสูง เช่น Cluster 0 และ 3 ถูกจำแนกได้อย่างแม่นยำโดยโมเดลนี้ จึงสามารถนำไปใช้เป็นเครื่องมือช่วยเฝ้าระวังและติดตามความเสี่ยงเชิงรุกได้อย่างมีประสิทธิภาพ

นอกจากนี้จากกราฟ Line Plot ที่แสดงค่ามาตรฐาน (Standardized Values) ของแต่ละตัวแปรในคลัสเตอร์ต่าง ๆ พบว่า ตัวแปรที่มีความแตกต่างสูงระหว่างกลุ่ม ได้แก่ Department_HR, Department_Marketing, Job_Role_Manager, Job_Role_Assistant และ Gender ซึ่งแสดงถึงการจำแนกกลุ่มพนักงานตามบทบาทและหน่วยงานได้อย่างมีประสิทธิภาพ ขณะเดียวกัน ตัวแปรด้านพฤติกรรมและทัศนคติ เช่น Job Involvement, Work-Life Balance และ Absenteeism ยังแสดงแนวโน้มที่สอดคล้องกับปัจจัยการลาออกอีกด้วย

สรุปได้ว่าการวิเคราะห์เชิงลึกด้วย K-Means Clustering ไม่เพียงช่วยจำแนกพนักงานตามลักษณะร่วม แต่ยังให้ insight ที่สามารถนำไปใช้วางแผนกลยุทธ์ HR ในเชิงรุก ทั้งในแง่การพัฒนา บริหารความสามารถ และการรักษาบุคลากรในแต่ละกลุ่มได้อย่างแม่นยำและมีประสิทธิภาพ

5.2.3 Association Rule Mining

ในการวิเคราะห์เชิงลึกเกี่ยวกับพฤติกรรมการลาออกของพนักงานโดยใช้เทคนิค Association Rule Mining พบว่ากฎหลายข้อสามารถตีความเพื่อเข้าใจ “รูปแบบความเสี่ยง” ที่เกิดจากการผสมผสานของคุณลักษณะเฉพาะของพนักงานแต่ละกลุ่มได้อย่างชัดเจน โดยกฎที่ถูกคัดเลือกมานั้นผ่านเกณฑ์การประเมินทั้งในด้าน support, confidence, และ lift ซึ่งสะท้อนถึงทั้งความแพร่หลาย ความน่าเชื่อถือ และความแรงของความสัมพันธ์ โดยเฉพาะกฎที่มี confidence สูงกว่า 70% และ lift มากกว่า 1.5 ถือว่าเป็นกฎที่มีศักยภาพในการใช้งานจริงในเชิงกลยุทธ์ ซึ่งสรุปได้เป็น 4 ประเด็นหลัก ได้แก่

1. เพศหญิง + รายได้ต่ำ + ไม่มีตำแหน่งหลัก = กลุ่มเสี่ยงสำคัญ

กฎที่พบว่ามี confidence สูงสุดถึง 81.41% และ lift สูงถึง 1.65 คือกฎที่ระบุว่า “Female”, “Income= $\leq$ 30k”, “Not Manager”, “Not Assistant” และ “Not in major departments” มีแนวโน้มสูงที่จะนำไปสู่ Attrition_Yes ซึ่งหมายความว่า พนักงานหญิงที่อยู่ในตำแหน่งทั่วไป รายได้น้อย และไม่ได้อยู่ในสายงานหลักขององค์กร มีแนวโน้มที่จะลาออกมากที่สุดในกลุ่มทั้งหมด

Insight นี้ชี้ให้เห็นถึง ความเปราะบางของพนักงานหญิงในองค์กร โดยเฉพาะกลุ่มที่อาจเผชิญกับ “เพดานแก้ว” (Glass Ceiling) ที่มองไม่เห็น แต่จำกัดโอกาสก้าวหน้า หรืออาจได้รับผลกระทบจากความไม่เท่าเทียมทางเพศในโอกาสในการเลื่อนตำแหน่ง นอกจากนี้ บทบาททางครอบครัวหรือภาระนอกงานที่ไม่ได้ถูกพิจารณาในการออกแบบนโยบายองค์กร อาจส่งผลทางอ้อมต่อความรู้สึกไม่มั่นคงในระยะยาว

2. รายได้ต่ำ + ไม่มีตำแหน่งเฉพาะ + ความสัมพันธ์กับหัวหน้าไม่ดี = ความเสี่ยงลาออกสูง

จากการวิเคราะห์กฎที่มี antecedents เช่น “Not Manager”, “Not Assistant”, “Income=<=30k” และ “MgrRel=Poor” ซึ่งมี consequent คือ “Attrition_Yes” พบว่ามี ค่า confidence สูงถึง 73.83% และ lift อยู่ที่ 1.50 ซึ่งแสดงให้เห็นถึงความน่าเชื่อถือของกฎและความเชื่อมโยงที่สูงกว่าความบังเอิญในเชิงสถิติอย่างชัดเจน โดยเฉพาะเงื่อนไขเรื่องความสัมพันธ์กับหัวหน้า (Relationship with Manager = Poor) ซึ่งมักจะเป็นปัจจัยที่ไม่ปรากฏชัดในข้อมูลเชิงโครงสร้าง แต่กลับมีอิทธิพลอย่างมากต่อความรู้สึกของพนักงาน

การไม่มีตำแหน่งเฉพาะ เช่น ไม่ได้เป็นผู้จัดการหรือผู้ช่วย อาจสะท้อนถึงบทบาทที่ไม่มีความสำคัญต่อองค์กร หรือรู้สึกว่าตนเองไม่มีโอกาสเติบโต เมื่อรวมกับรายได้ที่อยู่ในกลุ่มต่ำ และขาดความสัมพันธ์ที่ดีกับหัวหน้างาน จึงทำให้พนักงานรู้สึก “ไม่มีคุณค่า” หรือ “ไม่มีที่ยืน” ในองค์กร ส่งผลให้เกิดความรู้สึกอยากลาออกในที่สุด

3. พนักงานใหม่ (มีประสบการณ์ทำงานแค่ 1-2 บริษัท) = กลุ่มที่ยังไม่มั่นคง

กฎที่มี antecedents เช่น “CompaniesWorked=1-2”, “Not Assistant”, “Not Manager” และนำไปสู่ “Attrition_Yes” แสดงให้เห็นถึงค่า confidence 73.99% และ lift 1.50 ซึ่งชี้ว่า พนักงานที่ยังมีประสบการณ์ทำงานไม่มาก และยังไม่มีความพิเศษในองค์กร มีแนวโน้มที่จะลาออกสูง

ปัญหานี้อาจสะท้อนความรู้สึกของพนักงานที่ยัง “หาที่ของตัวเองไม่เจอ” หรือยังไม่สามารถปรับตัวเข้ากับวัฒนธรรมองค์กรได้ โดยเฉพาะในปีแรก ๆ ของการทำงานที่พนักงานอาจคาดหวังสิ่งหนึ่ง แต่ประสบกับสภาพแวดล้อมที่ต่างออกไป หากไม่มีระบบสนับสนุนที่ดี เช่น buddy system, mentoring program หรือช่องทาง feedback ที่ปลอดภัย พนักงานกลุ่มนี้ก็อาจตัดสินใจลาออกก่อนที่จะได้ลงทุนในการพัฒนาอย่างเต็มที่

4. ความสัมพันธ์กับหัวหน้า = ปัจจัยชี้ขาดในการลาออก

จากการวิเคราะห์กฎหลายรายการพบว่า “MgrRel=Poor” เป็นตัวแปรที่ปรากฏซ้ำมากที่สุด และมีความสัมพันธ์เชิงบวกอย่างชัดเจนกับการลาออก โดยกฎที่มีเงื่อนไขนี้มี lift มากกว่า 1.5 ในหลายกรณี แสดงให้เห็นว่า คุณภาพความสัมพันธ์ระหว่างหัวหน้ากับลูกน้องเป็นตัวแปรที่มีอิทธิพลสูงมาก

พนักงานที่มีปัญหากับหัวหน้างานอาจรู้สึกว่าได้ไม่ได้รับการยอมรับ ไม่มีโอกาสพูดคุย หรือขาดแรงสนับสนุนในการเติบโตในสายงาน ความรู้สึก “ห่างเหิน” นี้มักจะนำไปสู่ความรู้สึกหมดไฟหรือไม่อยากอยู่ต่อในองค์กร การจัดการปัญหานี้ไม่สามารถใช้การฝึกอบรมเพียงครั้งเดียวแล้วจบ แต่ควรพัฒนาเป็นวัฒนธรรมองค์กรที่ส่งเสริม ผู้นำที่ใส่ใจคนในทีม, มี EQ สูง, และสามารถปรับสไตล์การบริหารให้เหมาะกับบริบทของลูกน้องแต่ละคนได้

จากผลการวิเคราะห์ข้างต้น ยังสามารถเชื่อมโยงกับผลการทำโมเดลในส่วนอื่นของงานวิจัยได้อย่างน่าสนใจ โดยเฉพาะในส่วนของ โมเดล Classification ซึ่งได้ทำการประเมินด้วย Logistic Regression, Random Forest และ Neural Network โดยมีผลการจำแนกกลุ่มพนักงานที่ลาออกและไม่ลาออกอย่างแม่นยำ ตัวอย่างเช่น Random Forest ให้ค่า accuracy สูงสุดที่ 82.51% และ precision ของพนักงานที่ลาออก (Attrition) ถึง 87.45% ซึ่งโมเดลนี้เองที่ระบุความสำคัญของตัวแปรเช่น “Monthly_Income”, “Job_Role_Assistant”, “Gender”, และ “Relationship_with_Manager” ซึ่งสอดคล้องกับเงื่อนไขในหลายกฎของ Association Rule อย่างชัดเจน

ในขณะเดียวกัน เทคนิค Clustering (K-Means) ที่ใช้จัดกลุ่มพนักงานจากข้อมูลพฤติกรรมและคุณลักษณะก็สามารถยืนยันความสัมพันธ์ของกฎที่พบได้เช่นกัน โดยเฉพาะ Cluster 0 ซึ่งมีสัดส่วนมากที่สุด (49.3%) และมีพนักงานลาออกถึง 70.1% สะท้อนให้เห็นว่าเป็นกลุ่มที่มีลักษณะตรงกับกฎหลายข้อ ได้แก่ รายได้ต่ำ ไม่ได้อยู่ในตำแหน่งหลัก และมีลักษณะของความสัมพันธ์ในงานที่เปราะบาง ในขณะที่ Cluster 1-2 เป็นกลุ่มผู้จัดการและพนักงานอาวุโสที่มีความมั่นคงและลาออกน้อย (ต่ำกว่า 30%) ซึ่งช่วยยืนยันแนวโน้มเชิงพฤติกรรมในกลุ่มเสี่ยงได้อย่างมีนัยสำคัญ

หากองค์กรไม่ดำเนินการตาม insight ที่ได้จากการทำ Association Rule Mining เช่น การดูแลกลุ่มพนักงานรายได้น้อย การเสริมสร้างความสัมพันธ์ระหว่างหัวหน้า-ลูกน้อง หรือการออกแบบโปรแกรมพัฒนาความผูกพันที่เหมาะสม องค์กรอาจต้องแบกรับต้นทุนแฝงที่สูงมากจากการสูญเสียบุคลากร ทั้งในแง่ของค่าใช้จ่ายในการสรรหาและฝึกอบรมพนักงานใหม่ ไปจนถึงผลกระทบต่อการทำงานและขวัญกำลังใจของทีมงานเดิม นอกจากนี้ ยังอาจทำให้เกิดการลาออกแบบลูกโซ่หากไม่สามารถควบคุมปัจจัยสำคัญเหล่านี้ได้อย่างทันทั่วถึง

ดังนั้นการบูรณาการผลจาก Association Rule เข้ากับผลจาก Classification และ Clustering จึงช่วยให้องค์กรมองเห็นทั้ง “ใครมีแนวโน้มลาออก”, “เพราะอะไร”, และ “ควรออกแบบกลยุทธ์การบริหารอย่างไร” เพื่อรักษาพนักงานกลุ่มสำคัญและลดความสูญเสียเชิงโครงสร้างในระยะยาว

โดยสรุปข้อมูลเชิงลึกจาก Association Rule Mining แสดงให้เห็นว่า การลาออกของพนักงานไม่ได้เกิดขึ้นโดยบังเอิญ แต่มีรูปแบบที่สามารถตรวจจับได้จากการรวมกันของหลายปัจจัย ทั้งด้านตำแหน่งงาน รายได้ ประสิทธิภาพ และความสัมพันธ์ภายในองค์กร โดยเฉพาะ “ความสัมพันธ์กับหัวหน้างาน” และ “ระดับรายได้” ซึ่งเป็นปัจจัยซ้ำที่ปรากฏในกฎหลายข้อ ดังนั้น หากองค์กรสามารถนำข้อมูลเหล่านี้ไปใช้ในการออกแบบนโยบายบริหารทรัพยากรมนุษย์แบบเชิงรุก เช่น การดูแลกลุ่มเสี่ยง การส่งเสริมการเติบโตในอาชีพ และการอบรมผู้นำในระดับทีมงาน ก็จะสามารถลดอัตราการลาออกได้อย่างเป็นรูปธรรม และเพิ่มความยั่งยืนให้กับโครงสร้างบุคลากรในระยะยาว

5.2.4 การสังเคราะห์ผลการวิเคราะห์จากหลายเทคนิค

การเชื่อมโยงผลลัพธ์จากหลายเทคนิค เช่น Classification, Clustering, และ Association Rule Mining ช่วยให้เกิดความเข้าใจที่รอบด้านและลึกซึ้งมากขึ้นเกี่ยวกับพฤติกรรมลาออกของพนักงาน โดยแต่ละเทคนิคให้มุมมองเฉพาะที่เสริมกันได้อย่างมีประสิทธิภาพ

เทคนิค Classification ซึ่งเป็นการพัฒนาโมเดลเพื่อ “ทำนายความน่าจะเป็นในการลาออก” ของพนักงานแต่ละราย โดยใช้ตัวแปรต่าง ๆ เช่น รายได้ ชั่วโมงการทำงาน ความพึงพอใจในงาน และบทบาทหน้าที่ จากผลการทดลองพบว่า Random Forest ให้ผลลัพธ์ที่ดีที่สุด (Accuracy = 82.51%, Precision (Attrition) = 87.45%) และยังสามารถระบุฟีเจอร์สำคัญที่ส่งผลต่อการลาออก เช่น Monthly_Income, Job_Role_Assistant, Gender, และ Relationship_with_Manager ซึ่งชี้ว่า โมเดลสามารถจำแนกพนักงานกลุ่มเสี่ยงได้อย่างแม่นยำ

จากนั้นการใช้ Clustering (K-Means) ช่วยในการจัดกลุ่มพนักงานตามลักษณะร่วม เช่น รายได้ ตำแหน่งงาน ความสัมพันธ์กับหัวหน้า และประสบการณ์การทำงาน พบว่าข้อมูลสามารถจำแนกออกเป็น 5 กลุ่มชัดเจน โดย Cluster 0 มีสัดส่วนมากที่สุด (ประมาณ 49%) และมีอัตราการลาออกสูงถึง ~70% ซึ่งสอดคล้องกับลักษณะของพนักงานที่โมเดล Classification ระบุว่าเป็นกลุ่มเสี่ยง เช่น พนักงานระดับล่าง รายได้น้อย และไม่ได้อยู่ในสายงานหลัก ขณะที่ Cluster 1–2 ซึ่งมีผู้จัดการและพนักงานอาวุโส มีอัตราการลาออกต่ำกว่า 30% แสดงว่า Clustering ช่วยระบุ “กลุ่มเป้าหมาย” ที่ควรได้รับการดูแลเป็นพิเศษ

สุดท้าย Association Rule Mining เสริมมุมมองในเชิง “รูปแบบความสัมพันธ์” โดยค้นพบกฎที่ชี้ว่า พนักงานหญิง รายได้น้อย ไม่มีตำแหน่งหลัก และมีความสัมพันธ์กับหัวหน้าไม่ดี มีแนวโน้มลาออกสูง โดยเฉพาะกฎที่มีค่า confidence สูงถึง 81% และ lift มากกว่า 1.6 ซึ่งสอดคล้องกับปัจจัยสำคัญจากทั้ง Classification และลักษณะของ Cluster 0 เมื่อรวมทั้ง 3 เทคนิคเข้าด้วยกัน จะเห็นว่ามีผลสอดคล้องของ Insight อย่างชัดเจน

- ใครคือกลุ่มเสี่ยง (จาก Classification)
- กลุ่มนี้รวมอยู่ตรงไหนของพนักงานทั้งหมด (จาก Clustering)
- มีรูปแบบพฤติกรรมหรือเงื่อนไขใดที่เกิดขึ้นบ่อยในกลุ่มนี้ (จาก Association Rule)

สิ่งเหล่านี้ทำให้องค์กรสามารถออกแบบนโยบายได้อย่างแม่นยำ ไม่ว่าจะเป็นการกำหนดกลุ่มเป้าหมายเชิงปฏิบัติการ (Targeted Retention Program), การสร้างโมเดลพยากรณ์ภายในองค์กรแบบเรียลไทม์ หรือการสร้าง Dashboard เพื่อเฝ้าระวังพนักงานกลุ่มเสี่ยงอย่างมีประสิทธิภาพ

5.3 ข้อเสนอแนะ (Suggestion)

จากประสบการณ์ในการดำเนินโครงการวิเคราะห์การลาออกของพนักงานด้วยเทคนิคเหมืองข้อมูล (Data Mining) มีข้อเสนอแนะทั้งในด้านการทำงานวิจัยและการนำผลลัพธ์ไปใช้ในเชิงปฏิบัติดังนี้

1. ด้านการเตรียมข้อมูล (Data Preparation)

ควรให้ความสำคัญกับการทำ Data Cleaning และการเลือกฟีเจอร์อย่างรอบคอบ โดยเฉพาะการเข้ารหัสตัวแปรเชิงหมวดหมู่ (Categorical Encoding) และการจัดการค่าที่ขาดหายหรือผิดปกติ หากมีข้อมูลด้านเวลา (เช่น วันที่เริ่มงาน หรือวันลาออก) จะช่วยเสริมการวิเคราะห์เชิงลึกให้มีความแม่นยำมากขึ้นในเชิง Time Series หรือ Survival Analysis ได้

2. ด้านการเลือกโมเดล (Model Selection)

ควรทดลองเปรียบเทียบหลายโมเดลในแต่ละประเภท เช่น Tree-based, SVM, K-NN และรวมถึงการทำ Ensemble Method หรือการปรับ Hyperparameter อย่างเป็นระบบผ่าน Grid Search หรือ Random Search เพื่อเพิ่มประสิทธิภาพของตัวแบบ

3. ด้านการนำไปใช้ในองค์กร (Deployment)

ควรมีการจัดทำ Dashboard หรือ Tool ที่นำเสนอผลวิเคราะห์ให้ผู้บริหารหรือฝ่าย HR สามารถเข้าใจและใช้งานได้สะดวก ไม่ควรให้ผลลัพธ์จำกัดอยู่ในเชิงเทคนิคหรือการเขียนโค้ดเท่านั้น รวมถึงควรมีระบบอัปเดตข้อมูลและวิเคราะห์ซ้ำในระยะเวลา เพื่อสะท้อนการเปลี่ยนแปลงของพฤติกรรมพนักงานอย่างต่อเนื่อง

4. ข้อเสนอแนะสำหรับการศึกษาต่อ (Future Work)

สามารถขยายการวิเคราะห์ในอนาคตด้วยการใช้ข้อมูลจากหลายแหล่ง เช่น แบบสำรวจความพึงพอใจ (Employee Survey), ข้อมูล HRMS ที่ครอบคลุมเชิงเวลา หรือการทำ Predictive Modeling สำหรับพนักงานรายบุคคล (Individual Attrition Risk Scoring) เพื่อใช้ในการตัดสินใจเชิงเฉพาะเจาะจงมากขึ้น

เอกสารอ้างอิง

Bedi, M., & Aggarwal, R. (2023). Predictive analytics in human resource management using machine learning. SSRN Electronic Journal.

https://papers.ssrn.com/sol3/papers.cfm?abstract_id=4401862

BDI. (2021). ความรู้พื้นฐานเกี่ยวกับ Association Rule. Big Data Institute. <https://bdi.or.th/big-data-101/what-is-association-rule/>

Delić, A., & Šarić, J. (2021). Predictive modelling of employee turnover in the ICT industry. Croatian Operational Research Review, 12(2), 277–289. <https://hrcak.srce.hr/file/380463>

FDI Recruit. (n.d.). 10 ปัญหาที่พบบ่อยสำหรับ พนักงานออฟฟิศ พร้อมวิธีแก้ไข.

<https://fdirecruit.co.th/blogs/%E0%B8%9E%E0%B8%99%E0%B8%B1%E0%B8%81%E0%B8%87%E0%B8%B2%E0%B8%99%E0%B8%AD%E0%B8%AD%E0%B8%9F%E0%B8%9F%E0%B8%B4%E0%B8%A8/>

Han, J., Pei, J., & Kamber, M. (2011). Data Mining: Concepts and Techniques (3rd ed.). Morgan Kaufmann.

JobsDB. (n.d.-a). HR หัวใจหลักของการพัฒนาองค์กร ผู้สร้างวัฒนธรรมองค์กรให้แข็งแกร่ง.

<https://th.jobsdb.com/th/career-advice/article/%E0%B8%AD%E0%B8%A2%E0%B8%B2%E0%B8%81%E0%B8%97%E0%B8%B3%E0%B8%87%E0%B8%B2%E0%B8%99-hr-%E0%B8%97%E0%B8%B3%E0%B8%AD%E0%B8%A2%E0%B9%88%E0%B8%B2%E0%B8%87%E0%B9%84%E0%B8%A3>

JobsDB. (n.d.-b). รวม 20 เหตุผลในการลาออก ควรบอกบริษัทอย่างไรดี.

<https://th.jobsdb.com/th/career-advice/article/%E0%B9%80%E0%B8%AB%E0%B8%95%E0%B8%B8%E0%B8%9C%E0%B8%A5%E0%B8%A5%E0%B8%B2%E0%B8%AD%E0%B8%AD%E0%B8%81%E0%B8%88%E0%B8%B2%E0%B8%81%E0%B8%87%E0%B8%B2%E0%B8%99>

Kaggle. (n.d.). Employee attrition analysis and detection.

<https://www.kaggle.com/code/a3amat02/employee-attrition-analysis-and-detection>

MMP-LI. (2021). Deep Learning แบบฉบับคนสามัญชน EP.1. Medium. <https://medium.com/mmp-li/deep-learning->

[%E0%B9%81%E0%B8%9A%E0%B8%9A%E0%B8%89%E0%B8%9A%E0%B8%B1%E0%B8%9A%E0%B8%84%E0%B8%99%E0%B8%AA%E0%B8%B2%E0%B8%A1%E0%B8%B1%E0%B8%8D%E0%B8%8A%E0%B8%99-ep-1-neural-network-history-f7789236a9a3](https://medium.com/mmp-li/deep-learning-%E0%B9%81%E0%B8%9A%E0%B8%9A%E0%B8%89%E0%B8%9A%E0%B8%B1%E0%B8%9A%E0%B8%84%E0%B8%99%E0%B8%AA%E0%B8%B2%E0%B8%A1%E0%B8%B1%E0%B8%8D%E0%B8%8A%E0%B8%99-ep-1-neural-network-history-f7789236a9a3)

Patil, P., Patil, A., & Joshi, A. (2018). Employee attrition prediction. In Proceedings of the 2nd International Conference on Inventive Systems and Control (ICISC 2018) (pp. 378–383). ACM. <https://doi.org/10.1145/3224207.3224209>

Pradyasin. (2020, July 14). Random forest คืออะไร. Medium.

<https://medium.com/@pradyasin/random-forest->

[%E0%B8%84%E0%B8%B7%E0%B8%AD%E0%B8%AD%E0%B8%B0%E0%B9%84%E0%B8%A3-74d2a0af3d7](https://medium.com/@pradyasin/random-forest-%E0%B8%84%E0%B8%B7%E0%B8%AD%E0%B8%AD%E0%B8%B0%E0%B9%84%E0%B8%A3-74d2a0af3d7)

Rocket Thailand. (2020). วิทยาการข้อมูล หรือ Data Science คืออะไร?.

<https://www.rocket.in.th/blog/what-is-data-science/>

Skooldio. (2021, July 5). ความแตกต่างระหว่าง Linear Regression และ Logistic Regression.

<https://blog.skooldio.com/linear-regression-and-logistic-regression-differentiation/>

Supakorn, S. (2020). K-means clustering: การแบ่งกลุ่มย่อยเพื่อหาศูนย์กลาง. Medium.

https://medium.com/@si.supakorn_st/k-means-clustering-67a018f8cfb6

Techsauce. (n.d.). 'ทำไมถึงลาออกจากที่เก่า' รวม Good Reasons for Leaving สัมภาษณ์พุดยังงใจให้ได้งาน. <https://techsauce.co/talentsauce/life-hacks/good-reasons-for-leaving>

ธนภรณ์ พรรณราย. (2558). การวิเคราะห์ความพึงพอใจของพนักงานที่มีต่อปัจจัยที่มีผลต่อการลาออก [วิทยานิพนธ์ปริญญาโท, มหาวิทยาลัยสงขลานครินทร์].

<http://kb.psu.ac.th/psukb/bitstream/2016/17458/1/ธนภรณ์%20พรรณราย.pdf>

ภัทรพร เทียงธรรม. (2557). การวิเคราะห์ความพึงพอใจในการทำงานที่มีผลต่อการลาออกของพนักงาน (วิทยานิพนธ์ปริญญาโท, มหาวิทยาลัยธรรมศาสตร์). สืบค้นจาก

https://ethesisarchive.library.tu.ac.th/thesis/2014/TU_2014_5602030099_904_259.pdf